

Lista de Estudos

Preparação para a Prova de Recuperação — Módulo 3 — Inteli

Bloco A — Fundamentos, CRISP-DM e Preparação de Dados

Questão 1

Uma fintech está estruturando um novo projeto para prever se um cliente vai atrasar o pagamento de uma fatura de cartão de crédito. A equipe já tem acesso a um histórico de transações, mas ainda não definiu como o projeto será conduzido.

Descreva as seis fases do CRISP-DM aplicadas a esse projeto, explicando, para cada fase, uma atividade concreta que a equipe deveria realizar. Explique também por que a metodologia prevê retornos entre fases (por exemplo, da fase de modelagem de volta à de preparação dos dados) em vez de um fluxo estritamente linear.

Questão 2

Uma rede de clínicas está organizando uma base de pacientes com as colunas: *tipo_sanguineo*, *satisfacao_atendimento* (nota de 1 a 5), *temperatura_corporal* (°C) e *classificacao_risco* (baixo/médio/alto).

- Classifique cada uma dessas variáveis quanto ao tipo de dado (nominal, ordinal, intervalar ou razão), justificando cada classificação.
- A equipe percebeu que 12% dos registros têm *temperatura_corporal* preenchida como 0, o que é fisiologicamente impossível, e que o mesmo paciente aparece cadastrado duas vezes com grafias diferentes do nome. Relacione cada um desses dois problemas a um dos pilares de qualidade de dados e explique por que ele compromete a análise se não for tratado.

Questão 3

Uma varejista de moda vende pelo site próprio e por três marketplaces. Os dados de pedidos de cada canal chegam em formatos diferentes e precisam ser reunidos em um único repositório antes de qualquer modelagem.

- A equipe está decidindo entre um pipeline ETL e um ELT para consolidar esses dados, e entre armazená-los em um data lake ou em um data warehouse. Explique a diferença entre essas escolhas e recomende uma combinação para este cenário, justificando.
- Após consolidados, os dados brutos apresentam preços registrados como texto (ex.: "R\$ 129,90"), datas em três formatos distintos e uma coluna *categoria* com valores livres digitados manualmente (ex.: "vestido", "Vestido", "VESTIDOS"). Descreva as etapas de pré-processamento necessárias para deixar essa base pronta para um modelo preditivo, indicando qual técnica (limpeza, transformação, integração ou redução) resolve cada problema.

Questão 4

Um banco quer treinar um modelo para identificar transações fraudulentas. A base de treinamento tem 50 colunas (muitas delas pouco informativas) e, de 100.000 transações, apenas 400 são fraudes

confirmadas.

- Explique por que treinar o modelo diretamente com as 50 colunas originais pode prejudicar o desempenho e a interpretabilidade, e descreva uma estratégia para selecionar as características mais relevantes antes do treinamento.
- Explique por que a proporção de 400 fraudes em 100.000 transações é um problema para o treinamento do modelo, e descreva duas técnicas (uma de oversampling e uma de undersampling) que a equipe poderia aplicar, indicando um risco de cada uma.

Questão 5

Um e-commerce registra, para cada visita em que o cliente inicia a finalização de compra, as variáveis da tabela abaixo. A equipe quer treinar um modelo supervisionado que, no momento em que o cliente clica em "Finalizar Compra", estime se ele vai concluir o pedido ou abandonar o carrinho.

Variável	Descrição	Quando o valor é registrado
id_sessao	identificador da sessão de navegação	ao abrir o site
tempo_no_site_min	minutos de navegação até o clique em "Finalizar Compra"	até o clique em "Finalizar Compra"
itens_no_carrinho	quantidade de itens no carrinho	até o clique em "Finalizar Compra"
cupom_aplicado	se um cupom de desconto foi aplicado	até o clique em "Finalizar Compra"
tempo_no_checkout_seg	segundos que o cliente passou na tela de pagamento	do clique em "Finalizar Compra" até a saída da tela
pedido_concluido	se o pedido foi de fato concluído	ao final da sessão

Defina quais variáveis devem compor X e qual deve ser y para treinar esse modelo, explicando o critério usado para incluir ou excluir cada variável. Em seguida, explique por que uma dessas variáveis, se incluída em X, causaria vazamento de dados (data leakage) — e por que esse tipo de erro só costuma ser percebido quando o modelo já está em produção.

Bloco B — Aprendizado Supervisionado: Modelos, Métricas e Ajuste

Questão 6

Uma equipe treinou um modelo de classificação e obteve 99% de acurácia no conjunto de treino, mas apenas 61% no conjunto de teste. Ao repetir o experimento sem fixar uma semente aleatória, os resultados do conjunto de teste variaram entre 55% e 68% a cada nova execução.

- Explique o que esse padrão de resultados indica sobre o modelo, relacionando com os conceitos de overfitting, viés e variância.
- Explique por que dividir os dados em treino e teste é necessário mesmo quando o objetivo é apenas avaliar o desempenho do modelo, e por que fixar um *random_state* é importante neste cenário, dado que os resultados variaram entre execuções.

Questão 7

Uma fábrica registra, para cada máquina e cada turno de trabalho, as variáveis: *horas_operacao_turno*, *temperatura_media_c*, *vibracao_media_hz* (todas medidas durante o turno), *tecnico_responsavel* (id do técnico escalado para o turno) e *parou_por_falha* (se a máquina parou por falha mecânica durante o turno, medido ao final do turno). A equipe quer treinar um modelo que, a partir dos sensores, preveja se a máquina vai falhar naquele turno, para permitir uma parada preventiva antes que a falha ocorra.

Explique quais dessas variáveis podem compor X , indique se *tecnico_responsavel* deveria ser incluído e por quê, e identifique se alguma variável constitui vazamento de dados para o objetivo descrito, justificando sua resposta.

Questão 8

Uma escola quer prever se um aluno vai precisar de reforço escolar ("Sim"/"Não") a partir de uma única variável categórica: *frequencia* ("Regular" ou "Irregular"). Dos 10 alunos da base, 6 têm frequência Regular (dos quais 1 precisou de reforço) e 4 têm frequência Irregular (dos quais 3 precisaram de reforço).

- Calcule a entropia do conjunto completo (10 alunos) em relação à variável *precisa_reforco*, mostrando a fórmula utilizada.
- Calcule a entropia de cada subgrupo (Regular e Irregular) e explique, com base nesses valores, se dividir os alunos por *frequencia* reduz a incerteza sobre a necessidade de reforço.
- Compare, em linhas gerais, como uma árvore de decisão usaria esse cálculo de entropia para escolher variáveis, com a forma como o KNN classificaria um novo aluno. Em que tipo de cenário o KNN seria uma escolha menos adequada que a árvore de decisão?

Questão 9

Uma equipe de ciência de dados recebeu três problemas de classificação e precisa escolher, para cada um, entre Naive Bayes, SVM e Random Forest:

- classificar e-mails como "spam" ou "não spam" a partir da frequência de palavras no texto, com necessidade de resposta em poucos milissegundos por e-mail;
- classificar imagens de exames médicos em "tumor" ou "sem tumor" a partir de centenas de características extraídas da imagem, com poucos exames rotulados disponíveis;
- prever se um cliente vai cancelar um serviço, a partir de dezenas de variáveis de comportamento, priorizando um modelo cujas decisões possam ser explicadas ao time de negócio por meio da importância de cada variável.

Para cada cenário, indique qual dos três algoritmos você escolheria e justifique com base nas características do algoritmo e do problema.

Questão 10

Uma imobiliária treinou um modelo de regressão para estimar o valor de venda de imóveis, em reais. Avaliado em um conjunto de teste com 500 imóveis, o modelo obteve erro absoluto médio (MAE) igual a R\$ 15.000. A equipe pretende usar esse resultado para decidir se o modelo pode substituir a avaliação manual feita por um corretor.

Explique o que esse MAE significa exatamente, e aponte pelo menos duas interpretações equivocadas que a equipe poderia fazer a partir desse número (por exemplo, tratá-lo como um percentual, como

uma taxa de acerto, ou como um valor válido para qualquer imóvel do conjunto).

Questão 11

Uma distribuidora de energia treinou um modelo para prever o consumo diário de energia (em kWh) de bairros da cidade. No conjunto de teste, o modelo obteve $RMSE = 320$ kWh e $R^2 = 0,89$.

- a) Explique o que cada uma dessas duas métricas mede, na unidade em que é expressa (quando aplicável), e o que significa, em termos práticos, $R^2 = 0,89$ para a qualidade do modelo.
- b) A distribuidora observou que, em bairros com consumo muito acima da média, os erros do modelo são bem maiores do que em bairros de consumo típico. Explique por que o RMSE é mais sensível a esse tipo de erro do que o MAE seria, e em que situação isso é desejável ou indesejável para a distribuidora.

Questão 12

Uma equipe de dados avaliou dois modelos usando a mesma medida: a proporção de previsões iguais ao valor real no conjunto de teste. O Modelo A prevê o número de produtos que um cliente comprará no próximo mês (um número inteiro); o Modelo B prevê se um cliente vai cancelar a assinatura de um serviço ("cancela"/"não cancela"). Na base de teste do Modelo B, 92% dos clientes não cancelaram, e o Modelo B acertou 92% das previsões.

A equipe concluiu que o Modelo A, com 8% de acerto, é ruim, e que o Modelo B, com 92%, está pronto para uso. Avalie essa conclusão: explique por que a medida usada é inadequada para cada um dos dois modelos, proponha a medida (ou conjunto de medidas) mais adequada para cada caso, e explique especificamente por que os 92% do Modelo B podem ser enganosos.

Questão 13

Um banco avalia dois modelos com a mesma métrica: proporção de acertos exatos. O Modelo X prevê o valor da próxima fatura de um cliente (em reais); o Modelo Y prevê se um cliente vai entrar em inadimplência ("sim"/"não") em uma base de teste em que 96% dos clientes não ficam inadimplentes. O Modelo Y atingiu 96% de acerto e a equipe considerou o resultado excelente.

Proponha a forma correta de avaliar cada um dos dois modelos, explicando por que a proporção de acertos exatos é inadequada para o Modelo X e por que os 96% do Modelo Y não comprovam, por si só, que ele identifica bem quem vai ficar inadimplente. Indique quais métricas complementares você pediria para o Modelo Y antes de aprová-lo.

Questão 14

Uma equipe treinou um modelo de Random Forest para prever evasão de alunos e obteve resultados medianos com os parâmetros padrão da biblioteca. O gestor pediu para (i) melhorar o desempenho ajustando os parâmetros do modelo e (ii) apresentar, para cada aluno sinalizado como "risco de evasão", quais fatores mais pesaram na decisão do modelo.

- a) Explique a diferença entre GridSearch e RandomSearch como estratégias de busca de hiperparâmetros, e recomende qual delas você usaria se o modelo tivesse 6 hiperparâmetros com muitos valores possíveis cada, justificando pela viabilidade computacional.

- b) Explique por que avaliar essa busca de hiperparâmetros com uma única divisão treino/teste pode levar a uma escolha de parâmetros que não generaliza bem, e como a validação cruzada ajuda a mitigar esse risco.
- c) Explique, em linhas gerais, como uma técnica de explicabilidade como o SHAP poderia atender ao segundo pedido do gestor (mostrar os fatores que mais pesaram para cada aluno), e por que isso é diferente de apenas conhecer a importância geral das variáveis no modelo.

Questão 15

Uma academia de ginástica quer saber se existe relação entre o número de posts publicados nas redes sociais em uma semana e o número de matrículas novas fechadas naquela mesma semana. O gerente forneceu os dados das últimas 7 semanas, já carregados em um DataFrame chamado *dados*, com as colunas *semana*, *posts_redes_sociais* e *matriculas_novas*:

Semana	Posts nas redes	Matrículas novas
1	4	5
2	6	8
3	8	10
4	10	13
5	12	15
6	14	19
7	16	21

Considerando o fluxo dados → qualidade → treino/teste → treinamento → avaliação → previsão, descreva os passos para construir um modelo que estime o número de matrículas novas a partir do número de posts. Responda especificamente:

- a) Qual é a variável preditora (X) e qual é a variável-alvo (y)? Escreva o código pandas que define X e y a partir do DataFrame *dados*.
- b) Como você dividiria os dados em treino e teste, considerando que há apenas 7 observações? Justifique a proporção escolhida e explique por que fixar um *random_state* importa para a reprodutibilidade do experimento.
- c) Antes de escolher o modelo, como você verificaria, a partir dos próprios dados, se a relação entre posts e matrículas é aproximadamente linear? Que modelo você usaria e por quê?
- d) Após o treinamento, quais métricas você usaria para avaliar o modelo no conjunto de teste? O que significaria obter RMSE baixo e R^2 próximo de 1?
- e) As semanas estão em ordem cronológica, e tanto os posts quanto as matrículas crescem ao longo delas. Explique a diferença entre dividir os dados aleatoriamente e dividir cronologicamente (por exemplo, treinar com as semanas 1 a 5 e testar com as semanas 6 e 7), indique em que situação cada forma é mais adequada, e diga qual você adotaria para este problema, justificando com base no que o gerente quer prever.

Questão 16

Uma fábrica de peças automotivas usa um modelo de classificação para inspecionar peças na linha de produção e indicar se cada peça é "Defeituosa" ou "Boa". Peças indicadas como "Defeituosa" são separadas para inspeção manual; peças indicadas como "Boa" seguem direto para o estoque, sem inspeção adicional. A equipe aplicou o modelo a 10 peças cujo estado real já era conhecido por inspeção manual completa:

Peça	Estado real	Previsão do modelo
1	Defeituosa	Defeituosa
2	Boa	Boa
3	Defeituosa	Defeituosa
4	Boa	Defeituosa
5	Defeituosa	Boa
6	Boa	Boa
7	Boa	Boa
8	Defeituosa	Defeituosa
9	Boa	Defeituosa
10	Boa	Boa

- Classifique cada uma das 10 peças como TP, TN, FP ou FN, explicando o critério usado.
- Monte a matriz de confusão do modelo, com os totais de cada linha e coluna.
- Calcule acurácia, precisão, revocação e F1-score, apresentando a fórmula usada em cada caso.
- Nesse uso como inspeção automática, qual dos dois tipos de erro (falso positivo ou falso negativo) tem consequência mais grave para a fábrica? Justifique e indique qual métrica deve ser priorizada, mesmo que isso reduza a outra.
- Se a equipe ajustar o modelo para reduzir bastante os falsos negativos, o que tende a acontecer com os falsos positivos e com o volume de peças enviadas para inspeção manual? Explique a relação entre precisão e revocação por trás desse efeito.

Questão 17

Um provedor de e-mail usa um modelo de classificação para marcar mensagens como "Spam" ou "Não spam". Mensagens marcadas como "Spam" vão direto para a lixeira, sem notificar o usuário; mensagens marcadas como "Não spam" chegam normalmente à caixa de entrada. A equipe aplicou o modelo a 10 e-mails cujo rótulo real já era conhecido:

E-mail	Rótulo real	Previsão do modelo
1	Spam	Spam
2	Não spam	Não spam
3	Spam	Spam
4	Não spam	Spam
5	Não spam	Não spam
6	Spam	Não spam
7	Não spam	Spam
8	Spam	Spam
9	Não spam	Não spam
10	Não spam	Não spam

- Monte a matriz de confusão do modelo e calcule precisão e revocação da classe "Spam".
- Nesse cenário, marcar um e-mail legítimo como spam (o e-mail vai para a lixeira sem o usuário ver) tem uma consequência diferente de deixar passar um spam para a caixa de entrada. Explique qual erro é mais grave aqui e qual métrica (precisão ou revocação) deveria ser priorizada — contrastando com um cenário de triagem em que o erro mais grave é o oposto (como um exame médico em que deixar passar um caso positivo é mais grave que gerar um falso alarme).
- Se a equipe tornar o modelo mais rigoroso para classificar como spam (reduzindo os falsos positivos), o que tende a acontecer com os falsos negativos? Explique essa relação.

Bloco C — Aprendizado Não Supervisionado e Sistemas de Recomendação

Questão 18

Uma rede de academias quer agrupar seus alunos em perfis de comportamento a partir de 18 variáveis (frequência semanal, horário preferido, modalidades praticadas, tempo médio de permanência, entre outras), sem usar nenhum rótulo prévio.

- Explique por que o K-means é um algoritmo adequado para esse objetivo, e descreva o papel do valor de K nesse processo.
- A equipe testou valores de K entre 2 e 8 e não conseguiu identificar um "cotovelo" claro no gráfico de inércia. Explique o que é o Elbow Plot, por que ele pode não apresentar um ponto claro em alguns conjuntos de dados, e como a análise de silhueta poderia ajudar a decidir o valor de K nesse caso.

c) Com 18 variáveis, a equipe suspeita que esteja enfrentando a chamada maldição da dimensionalidade. Explique o que esse problema significa para o agrupamento e como o PCA poderia ser usado antes do K-means para mitigá-lo, incluindo o que se perde ao reduzir as variáveis originais a componentes principais.

Questão 19

Uma livraria online recomenda livros por filtragem colaborativa usuário-usuário: para cada usuário, o sistema encontra usuários com histórico de compras parecido e recomenda os livros que eles compraram. Cada livro tem gênero, autor e faixa de preço cadastrados. No cadastro, o usuário informa apenas faixa etária e cidade. A equipe percebeu que usuários recém-cadastrados não recebem nenhuma recomendação até terem pelo menos 5 compras, e que muitos abandonam a loja antes disso.

Considerando os dados disponíveis para um usuário recém-cadastrado, proponha uma mudança que permita gerar recomendações personalizadas já na primeira visita, explicando por que ela resolve o problema e por que simplesmente trocar a filtragem usuário-usuário por uma filtragem item-item não resolveria.

Bloco D — Ajuste Automatizado e Produção de Modelos

Questão 20

Uma pequena consultoria de dados fechou dois projetos. No primeiro, o cliente quer testar rapidamente vários algoritmos de classificação para saber quais valem a pena investigar a fundo, sem que a consultoria precise programar cada modelo manualmente. No segundo, um modelo de regressão já treinado e validado precisa ser colocado em uso por uma equipe de vendas que não sabe programar, acessando o modelo por uma interface simples na web.

- a) Para o primeiro projeto, explique o que é uma ferramenta de AutoML como o Pycaret, o que ela automatiza e por que ela não substitui a etapa de entendimento do problema feita pela equipe de dados.
- b) Para o segundo projeto, descreva os passos necessários para colocar o modelo em uso: como exportá-lo com pickle ou joblib, por que usar um Pipeline do scikit-learn (em vez de aplicar o pré-processamento manualmente antes de cada previsão) e como uma ferramenta como o Streamlit permite que a equipe de vendas use o modelo sem programar.
- c) Explique o papel do MLflow nesse processo, especialmente se a consultoria precisar treinar várias versões do modelo ao longo do tempo e comparar seus resultados.