

AUTOESTUDO

8h às 10h

Explore os materiais e execute os primeiros exemplos.

| Stand-up daily: alinhar antes de investigar

15 min

10:00 → 10:15

1

Status

O que foi compreendido?

2

Próximos passos

Qual exemplo será executado?

3

Impedimentos

Instalação, código ou conceito?

Registre o bloqueio com a mensagem de erro completa.

AULA 3 • SEMANA 1

Introdução ao Pandas, Numpy e bibliotecas gráficas - Exploração de Dados

NumPy • Pandas • Matplotlib • Seaborn

Profª Dra. Crishna Irion

Autoestudo: quatro portas para a prática

1

NumPy

arrays, dimensões e operações

2

Pandas

tabelas, seleção e limpeza

3

Estatística

centro, dispersão e quartis


4

Visualização

Matplotlib e Seaborn

Meta: chegar à aula com pelo menos um exemplo executado e uma dúvida registrada.

DIAGRAMA DO MÓDULO



Hoje vamos transformar dados em perguntas respondíveis

1

Reconhecer

estrutura, tipo e qualidade

2

Manipular

arrays e DataFrames

3

Resumir

medidas e agrupamentos

4

Visualizar


distribuições e relações

5

Comunicar

achado + evidência + limite

| Explorar é um ciclo de perguntas e verificações



Uma conclusão útil sempre aponta a evidência — e reconhece seus limites.

Desafio de abertura: o caso da venda impossível

R\$ 18.940

Uma venda aparece cinco vezes acima do padrão.

Antes de apagar, investigue:

É erro de digitação?

É uma compra legítima rara?


Houve promoção ou fraude?

Qual regra definiu o valor como extremo?

Outlier é uma pista — não um veredito.


Nossa caixa de ferramentas tem papéis diferentes

NumPy



cálculo vetorizado

Pandas



**tabelas e
transformação**

Matplotlib



controle do gráfico

Seaborn



**gráficos
estatísticos**

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
```

Colab reduz a preparação; VS Code amplia o controle

GOOGLE COLAB

- roda no navegador
- facilita compartilhar notebooks
- bibliotecas comuns já instaladas
- sessões e arquivos são temporários

VS CODE + PYTHON

- ambiente local persistente
- controle de versões e arquivos
- exige Python e pip configurados
- ideal para projetos maiores

```
pip install numpy pandas matplotlib seaborn
```

PARTE 1

NumPy

Arrays multidimensionais e operações vetorizadas.

NumPy aplica uma operação a muitos valores

```
unidades = np.array([2, 5, 1, 4])  
precos = np.array([120, 35, 250, 80])  
  
faturamento = unidades * precos  
faturamento.sum()
```

[240, 175, 250, 320]



985

Sem escrever um laço para cada posição.

Lista e array parecem iguais — mas se comportam diferente

LISTA

```
valores = [1, 2, 3]
valores * 2
# [1, 2, 3, 1, 2, 3]
```

ARRAY

```
valores = np.array([1, 2, 3])
valores * 2
# [2, 4, 6]
```

Lista repete a sequência; array multiplica cada elemento.

shape, ndim e dtype descrevem a estrutura

```
matriz = np.array([
    [2, 120.0, 240.0],
    [5, 35.0, 175.0],
    [1, 250.0, 250.0]
])
```

shape (3, 3)

linhas × colunas


ndim 2

número de dimensões

dtype float64

tipo armazenado

Índices localizam; fatias recortam



```
arr[0]      # 10  
arr[1:4]    # [20, 30, 40]  
arr[arr > 25] # [30, 40, 50]
```

A condição também pode funcionar como máscara de seleção.

Vetorização torna a intenção visível

COM LAÇO

```
resultado = []  
for valor in vendas:  
    resultado.append(valor * 1.10)
```

VETORIZADO

```
resultado = vendas * 1.10
```

mais curto

mais direto

Primeiro pense na operação; depois pense no elemento.

Desafio NumPy: três respostas em uma linha

```
notas = np.array([6.5, 8.0, 7.5, 9.0, 5.0])
```

1

Qual é a média?

2

Qual é a maior nota?

3

Quantas são ≥ 7 ?

Solução no notebook — tente antes de executar a célula seguinte.

PARTE 2

Pandas

DataFrames para inspecionar, selecionar, limpar e resumir.

Series é uma coluna; DataFrame é uma tabela

SERIES

Tecnologia

Casa

Esportes

DATAFRAME

categoria	unidades	vendas
Tecnologia	2	240
Casa	5	175
Esportes	1	250

Cada coluna preserva seu próprio tipo de dado.

Um dicionário pode nascer como DataFrame

```
dados = {  
    'categoria': ['Casa', 'Tech',  
    'Papeleria'],  
    'unidades': [5, 2, 8],  
    'vendas': [175, 620, 240]  
}  
  
df = pd.DataFrame(dados)
```

categoria	unidades	vendas
Casa	5	175
Tech	2	620
Papeleria	8	240

df

Inspeção antes de transformar

df.head()

primeiras linhas

df.shape

linhas × colunas

df.dtypes

tipos

df.info()

estrutura + nulos

df.isna().sum()

ausentes

df.duplicated().sum()

duplicatas

A primeira pergunta não é 'como limpar?', mas 'o que tenho aqui?'.

Seleção responde: quais linhas e quais colunas?

```
df.loc[
    (df['vendas'] > 1200) &
    (df['desconto'] <= 0.10),
    ['data', 'categoria', 'vendas']
]
```

LINHAS

condições booleanas

+

COLUNAS

lista de nomes

Use parênteses em cada condição.

Limpar exige uma decisão explicável

1

Ausentes

preencher, manter ou remover?

2

Duplicatas

repetição real ou cópia?

3

Tipos

a coluna representa o quê?

4

Extremos

erro, exceção ou evento raro?


```
df['avaliacao'] = df['avaliacao'].fillna(df['avaliacao'].median())  
df = df.drop_duplicates()
```

Nunca use zero automaticamente sem discutir o significado.


groupby transforma linhas em comparação

```
df.groupby('categoria').agg(  
    vendas_total=('vendas', 'sum'),  
    ticket_mediano=('vendas', 'median'),  
    avaliacao_media=('avaliacao', 'mean')  
)
```

SEPARAR



APLICAR



COMBINAR

grupos → função → tabela-resumo

Desafio Pandas: encontre a história escondida

1

Conte ausentes e duplicatas

2

Filtre Tecnologia + App

3

Compare ticket por região

4

Justifique uma limpeza

Regra do grupo: toda transformação deve ter uma frase de justificativa.

PARTE 3


Estatística Descritiva

Resumir o centro, a dispersão e a posição dos dados.



Centro não é um único número


Média



soma ÷ quantidade

sensível a extremos

Mediana



valor central

robusta à assimetria

Moda



valor mais frequente

útil também em categorias

Com uma venda extrema, média e mediana podem contar histórias diferentes.

Dispersão mostra quanto os valores se afastam

1

Amplitude

máximo – mínimo

2

Variância

desvios ao quadrado

3

Desvio-padrão

distância típica da média

4


IQR

Q3 – Q1

```
df['vendas'].describe()
```

describe() reúne contagem, média, desvio-padrão, quartis e extremos.

O boxplot resume cinco números e destaca extremos



Q1 25% abaixo

Mediana centro robusto

Q3 75% abaixo

IQR $Q3 - Q1$

Investigue o ponto; não apague por reflexo.

PARTE 4

Visualização de Dados

Escolher o gráfico a partir da pergunta — não do efeito visual.



Cada pergunta pede uma forma visual

1


Comparar



barras

2

Evoluir



linha

3

Distribuir



histograma

4

Relacionar



dispersão

5

Detectar extremos



boxplot

Evite pizza com muitas categorias: comparar ângulos é mais difícil que comparar comprimentos.

Matplotlib oferece controle explícito do gráfico

```
plt.bar(categoria, vendas,  
color='#0D7377')  
plt.title('Vendas por categoria')  
plt.xlabel('Categoria')  
plt.ylabel('Vendas (R$)')  
plt.show()
```





Figura → eixos → marcas → rótulos


Seaborn aproxima o gráfico da pergunta estatística

```
sns.histplot(  
    data=df,  
    x='vendas',  
    bins=24,  
    kde=True  
)  
plt.show()
```



O histograma mostra concentração, assimetria e caudas.

Correlação organiza pistas — não prova causas



+1

relação positiva

0

sem relação linear

-1

relação negativa

Pergunte sempre: pode haver uma terceira variável?

Uma EDA completa conecta código e raciocínio

1

Pergunta

O que quero compreender?

2

Qualidade

Posso confiar nos dados?

3

Resumo

Qual é o padrão central?

4

Visual

Que forma revela melhor?

5

Achado

O que a evidência permite dizer?

```
df.info()
df.isna().sum()
df.describe()
df.groupby('categoria')['vendas'].median()
sns.boxplot(data=df, x='categoria',
             y='vendas')
```

Código executa a pergunta; não substitui a pergunta.

Desafio final: relatório de três achados

1

Qualidade

um problema encontrado e a
decisão tomada

2

Comparação

categorias, regiões ou
canais

3

Relação

duas variáveis numéricas

Cada achado precisa de pergunta + código + evidência + conclusão + limitação.

Entrega: notebook executado e organizado.

Dados não falam sozinhos.

Nós fazemos perguntas, verificamos evidências e comunicamos limites.

Dúvidas? Vamos investigar.



PERGUNTA
→ **EVIDÊNCIA**
→ **CONCLUSÃO**


PARTE 5

Mão na Massa

Bora?



Desafio pandas



<https://encurtador.com.br/dZcW>

Dúvidas? Vamos conversar.

Profª Dra. Crishna Irion

crishna.irion@prof.inteli.edu.br

