

8h às 10h

Explore os materiais e execute o notebook-base.

Autoestudo: uma trilha, não uma lista

1

Limpeza de dados com exemplos em Python (FreeCodeCamp)

2

Pré-processamento de dados (conceito + prática)

3

Adequação de variáveis numéricas e categóricas

4

Diferenças entre ETL e ELT

5

Seleção de características

6

Diferenças entre Data Lakes e Data Warehouses

| Stand-up daily: antes de transformar

15 min

10:00 → 10:15

1

Status

Qual material foi explorado?

2

Experimento

Qual célula foi executada?


3

Impedimento

Dado, código ou conceito?

Traga a mensagem de erro e a célula que a produziu.

DIAGRAMA DO MÓDULO



AULA 4 • SEMANA 3

Pré-processamento e Feature Engineering

Dados preparados • Atributos úteis • Pipeline reproduzível

Prof^a Dra. Crishna Irion

Agenda do Encontro

1

Live Coding

Exploração de Dados

2

Conceitos

ETL x ELT
Data Lake vs. Data Warehouse
Prevenção de Data Leakage
Limpeza de Dados
Outliers
Adequação Numérica & Categórica
Engenharia de Atributos

3

Prática

ETL x ELT
Data Lake vs. Data Warehouse
Prevenção de Data Leakage
Limpeza de Dados
Outliers
Adequação Numérica & Categórica
Engenharia de Atributos

PARTE 1

Live coding

Abra o colab.

Copie os arquivos desse drive: <https://encurtador.com.br/AwGW>

Exercícios: <https://encurtador.com.br/aIAI>

Agenda do Encontro

1

Live Coding

Exploração de Dados

2

Conceitos



ETL x ELT
Data Lake vs. Data Warehouse
Prevenção de Data Leakage
Limpeza de Dados
Outliers
Adequação Numérica & Categórica
Engenharia de Atributos

3

Prática

ETL x ELT
Data Lake vs. Data Warehouse
Prevenção de Data Leakage
Limpeza de Dados
Outliers
Adequação Numérica & Categórica
Engenharia de Atributos

Pipeline de Aprendizagem de Máquina



Fonte: Adaptado de Faceli et al. (2021)

Desafio de abertura: por que este cliente quebra o código?

```
idade = NaN  
renda = R$ 4.500  
cidade = São Paulo  
plano = Básico
```

O algoritmo espera números.

O que significa o valor ausente?

Como retirar 'R\$' e o separador?

Como representar a cidade?

A escala da renda domina a idade?

Em duplas: escolham a primeira decisão — e defendam o motivo.


| Pré-processar é atribuir significado operacional



A mesma regra deverá funcionar amanhã, com novos dados.


ETL e ELT mudam a ordem da transformação

ETL



Regras aplicadas antes do destino.

ELT



O destino executa a transformação.

A escolha depende de governança, latência, custo e capacidade da plataforma.

Data lake e data warehouse podem coexistir

DATA LAKE

dados brutos e variados
schema pode vir depois
exploração e ciência de dados
exige governança para não virar caos

DATA WAREHOUSE

dados estruturados e curados
schema definido para consumo
BI e análises recorrentes
consistência e desempenho

Arquitetura responde ao uso — não à sigla da moda.

PARTE 2

Pré-processamento

Limpar, integrar, transformar e reduzir sem perder o significado.

Quatro operações organizam o pré-processamento

1

Limpeza

ausentes, ruído,
duplicatas

2

Integração

fontes, chaves e
conflitos

3

Transformação

escala, encoding e
formato

4

Redução

linhas, colunas ou
dimensões

Nem todo projeto precisa das quatro na mesma intensidade.

Exploração + Preparação



1. Diagnóstico Inicial

Verificação de estrutura e completude antes de qualquer remoção:

```
df.info()
df.describe()
df.value_counts()
df.isnull().sum()
df.isna()
df.duplicated().sum()
df.dtypes
```



2. Tratamento de Valores Ausentes

Ausência é um fato; o método escolhido reflete uma hipótese:

```
df['idade'].fillna(df['idade'].median())
df['idade'].fillna(df['idade'].mean())
```

A primeira pergunta não é “como limpar?”, mas “o que encontrei?”.

Exploração + Preparação



3. Remoção de Duplicatas

Decisão baseada em regras de negócio e chaves de identidade:

```
df['cidade'] = df['cidade'].str.strip()  
df = df.drop_duplicates()
```



4. Tratamento de Outliers

Outliers podem representar erro de digitação, evento raro ou sinal valioso. A regra matemática apenas aponta; o contexto decide:

```
# Amplitude Interquartil (IQR)  
q1 = df['renda'].quantile(0.25)  
q3 = df['renda'].quantile(0.75)  
IQR = q3 - q1  
limite_inferior = q1 - 1.5 * IQR  
limite_superior = q3 + 1.5 * IQR  
df_limpo =  
df[df['renda'].between(limite_inferior, limite_superior)]
```

Duplicata e inconsistência exigem uma regra de identidade

```
df.duplicated().sum()
df.drop_duplicates()

df['cidade'] = (
    df['cidade'].str.strip().str.title()
)
```

Mesma pessoa?
Mesma compra?
Mesmo evento?

Sem chave e contexto, duas linhas iguais podem ser eventos legítimos.

Remover é uma decisão de negócio, não apenas um método Pandas.


Outlier pode ser erro, evento raro ou informação

1,5 × IQR

Um critério sinaliza; o contexto decide.

- 1 Verificar**
origem, unidade e digitação
- 2 Comparar**
registros semelhantes
- 3 Decidir**
manter, limitar, transformar ou remover

Separe antes de aprender as transformações



Se o teste ajuda a definir a transformação, ele deixa de representar o futuro.

PARTE 3

Transformação

Adequar números e categorias ao que o algoritmo consegue ler.

Escalas diferentes podem distorcer o modelo

idade

25 → 52

renda mensal

2.500 → 9.000

Sem escalonamento

A renda varia em milhares; a idade, em dezenas. Em métodos sensíveis à escala, a renda pode dominar o cálculo.

Escalonar não torna a feature mais importante — apenas muda sua unidade.

Padronizar ou normalizar?

STANDARD SCALER

$$z = (x - \text{média}) / \text{desvio}$$

centra em torno de 0
escala pelo desvio-padrão
não limita a uma faixa fixa

MIN-MAX

$$x' = (x - \text{mín}) / (\text{máx} - \text{mín})$$

mapeia para uma faixa
comum: 0 a 1
sensível a valores extremos


Categorias precisam de representação — não de hierarquia inventada

cidade

São Paulo

Rio de Janeiro

Belo Horizonte



cidade_BH	cidade_RJ	cidade_SP
0	0	1
0	1	0
1	0	0

One-Hot Encoding cria uma coluna binária por categoria.

Ordinal só faz sentido quando a ordem existe

ORDINAL

baixo < médio < alto

Uma ordem real pode ser codificada.


NOMINAL

azul ≠ verde ≠ coral

Atribuir 1, 2 e 3 inventaria uma distância que não existe.

LabelEncoder foi projetado para o alvo y, não para as colunas de entrada X.

ColumnTransformer aplica regras por coluna



Cada subconjunto segue uma trilha; os resultados são concatenados.

Desafio relâmpago: escolha a transformação

1

renda_mensal

numérica com ausentes

2

cidade

nominal com ausentes

3

satisfação

baixo, médio, alto

4

data_compra

data e hora


Em duplas: proponham uma regra e um risco para cada variável.

PARTE 4

Feature Engineering

Criar representações que aproximem o dado do fenômeno.

Uma feature útil nasce de uma hipótese



Hipótese: o valor típico de cada compra informa melhor do que apenas o total.

Datas, razões e interações criam novas pistas

1

Data → contexto

mês, dia da semana, tempo
desde evento

2

Razão → intensidade

ticket médio, gasto por visita,
renda por pessoa

3

Interação → combinação

preço × quantidade, idade ×
canal

Evite criar dezenas de features sem hipótese: complexidade também custa.

Criar, selecionar e extrair são operações diferentes

1

Feature engineering

cria uma variável nova
com conhecimento do
problema

2

Feature selection

mantém um subconjunto
das variáveis existentes

3


Feature extraction

projeta novas dimensões
a partir de várias features

Exemplo de extração: PCA. Hoje, o foco está em criar e selecionar.

| Selecionar features reduz ruído e custo

20 colunas



5 colunas

menos variáveis para coletar e manter
menor risco de ajustar ruído
interpretação potencialmente mais simples
treinamento e inferência mais leves

Menos não é automaticamente melhor: valide o desempenho.

Três famílias de seleção fazem perguntas diferentes

1

Filtro

pontua antes do modelo
ex.: correlação, qui-quadrado

2

Wrapper

testa subconjuntos
ex.: seleção recursiva

3

Embedded

seleciona durante o ajuste
ex.: L1, árvores

A seleção precisa acontecer dentro da validação — nunca usando todo o conjunto antes do teste.

Vazamento produz uma previsão frágil


LEAKAGE

Informação indisponível no momento da previsão entra nas features ou nas regras de preparação.

usar média calculada com o teste
selecionar features olhando todo o conjunto
usar informação registrada depois do evento
preencher o alvo com dados futuros

Pergunta-chave: eu teria este dado no instante da decisão?

Pipeline transforma a sequência em um objeto reproduzível



```
pipeline.fit(X_treino, y_treino)  
pipeline.predict(X_teste)
```

PARTE 5

Prática guiada

Um notebook pequeno para enxergar cada decisão.



O notebook acompanha uma única base de 12 clientes

1

Diagnóstico

ausentes + duplicata

2

Limpeza

remover repetição

3

Nova feature

ticket médio

4

Transformação

imputar + escalar + one-hot

5

Seleção

manter cinco features



<https://encurtador.com.br/YFxc>

Missão final: defenda uma mudança no pipeline

1

Alteração

crie uma feature ou troque
uma regra

2

Hipótese

explique por que isso pode
ajudar

3

Avaliação

diga como compararia o
resultado

Entregue: notebook executado + três frases de justificativa.

Vale Participação!!! A Ponderada será a tarde

O modelo aprende a representação.

Pré-processar é decidir o que cada valor passará a significar.

Dúvidas? Vamos testar a hipótese.

X

DADO BRUTO
→ **REGRAS**
→ **FEATURES**
→ **MODELO**

Dúvidas? Vamos conversar.

Profª Dra. Crishna Irion

crishna.irion@prof.inteli.edu.br

