

8h às 10h

Explore os materiais e leve uma decisão de negócio.

Autoestudo: seis modelos para discutir

1

Matriz de confusão e métricas

2

Árvore de decisão e entropia

3

Regressão logística

4

Naive Bayes

5

SVM em alta dimensionalidade

6

Random Forest e ensembles

| Daily

15 min

10:00 → 10:15

1

Em pé

2

Tasks

Como está o grupo?

3

Definições

DIAGRAMA DO MÓDULO



Aprendizado Supervisionado II

Contexto - Métricas - Árvores. - Ensembles

Prof^a Dra. Crishna Irion

PARTE 1

Avaliar antes de escolher

As métricas são leituras diferentes da mesma matriz

ACURÁCIA

$$(TP + TN) / (TP + TN + FP + FN)$$

quantos acertos no total?

PRECISÃO

$$TP / (TP + FP)$$

entre os alertas, quantos acertou?

RECALL / SENSIBILIDADE

$$TP / (TP + FN)$$

entre os positivos reais, quantos encontrou?

ESPECIFICIDADE

$$TN / (TN + FP)$$

entre os negativos reais, quantos descartou?

$$F1 = 2 \times (\text{Precisão} \times \text{Recall}) / (\text{Precisão} + \text{Recall})$$

A métrica certa depende do custo do erro

1

PRECISÃO

Priorize quando falsos positivos geram alarmes ou custos desnecessários

2

RECALL

Priorize quando perder um caso positivo é mais grave.
Quanto maior o Recall, menor é o número de Falsos Negativos.

3

F1-SCORE

Métrica que usa a média harmônica porque ela é extremamente sensível a valores baixos.
Use quando precisão e recall precisam de equilíbrio.

99% de acurácia pode ser ruim

Se apenas 1% dos casos é positivo, prever sempre “negativo” já produz 99% de acurácia — sem encontrar nenhum positivo.

A acurácia funciona muito bem quando os dados são balanceados.

Porém, ela se torna completamente enganosa se os dados forem desbalanceados.

Defina a classe positiva antes de preencher TP, TN, FP e FN.

Dois modelos: a decisão muda com o erro mais caro

MODELO A

TN 850 · FP 100

FN 10 · TP 40

Acurácia: 89%

Recall: 80%

MODELO B

TN 900 · FP 50

FN 25 · TP 25

Acurácia: 92,5%

Recall: 50%

Se falsos negativos custam mais, escolha A: recall 80% > 50%, mesmo com menor acurácia.

Árvore de Decisão - A árvore começa medindo a impureza do conjunto

Entropia é o grau de impureza do conjunto de dados, ajudando a quantificar o estado de desordem, aleatoriedade ou incerteza em um conjunto de dados.

$$\text{Entropia}(S) = - \sum p_i \cdot \log_2(p_i)$$

Na tabela ao lado

Risco alto = 6/14

Risco moderado = 3/14

Risco baixo = 5/14

$$\text{Entropia}(S) = 1,53$$

O melhor corte será o que mais reduzir essa impureza.

	A	B	C	D	E
1	historia	divida	garantias	renda	risco
2	ruim	alta	nenhuma	0_15	alto
3	desconhecida	alta	nenhuma	15_35	alto
4	desconhecida	baixa	nenhuma	15_35	moderado
5	desconhecida	baixa	nenhuma	acima_35	alto
6	desconhecida	baixa	nenhuma	acima_35	baixo
7	desconhecida	baixa	adequada	acima_35	baixo
8	ruim	baixa	nenhuma	0_15	alto
9	ruim	baixa	adequada	acima_35	moderado
10	boa	baixa	nenhuma	acima_35	baixo
11	boa	alta	adequada	acima_35	baixo
12	boa	alta	nenhuma	0_15	alto
13	boa	alta	nenhuma	15_35	moderado
14	boa	alta	nenhuma	acima_35	baixo
15	ruim	alta	nenhuma	15_35	alto

Ganho de informação compara a impureza antes e depois

$$\text{Ganho}(S,A) = \text{Entropia}(S) - \sum (|S_v| / |S|) \cdot \text{Entropia}(S_v)$$

HISTÓRIA

Boa: 5/14 $\rightarrow H = 1,37$

Desconhecida: 5/14 $\rightarrow H = 1,52$

Ruim: 4/14 $\rightarrow H = 0,81$

$$\text{Ganho} = 1,53 - (5/14 \times 1,37) - (5/14 \times 1,52) - (4/14 \times 0,81) = 0,26$$

DÍVIDA

Alta: 7/14 $\rightarrow H = 1,38$

Baixa: 7/14 $\rightarrow H = 1,56$

$$\text{Ganho} = 1,53 - (7/14 \times 1,38) - (7/14 \times 1,56) = 0,06$$

Maior ganho = maior redução de incerteza.

Renda produz a maior redução de impureza

GARANTIAS

Nenhuma: $11/14 \rightarrow H = 1,44$

Adequada: $3/14 \rightarrow H = 0,92$

$$\text{Ganho} = 1,53 - (11/14 \times 1,44) - (3/14 \times 0,92) = 0,20$$

RENDA

< 15 : $3/14 \rightarrow H = 0,00$



15 a 35: $4/14 \rightarrow H = 1,00$

> 35 : $7/14 \rightarrow H = 1,15$

$$\text{Ganho} = 1,53 - (3/14 \times 0) - (4/14 \times 1) - (7/14 \times 1,15) = 0,66$$

0,66 é o maior ganho $\rightarrow$ RENDA será a raiz

A raiz usa o atributo com maior ganho



A árvore repete o cálculo em cada subconjunto até atingir folhas puras ou um critério de parada.

Profundidade controla o compromisso entre simplicidade e ajuste

1

POUCA PROFUNDIDADE

regras simples; pode deixar
padrões de fora

2

BOM COMPROMISSO

captura relações sem
memorizar o treino

3

PROFUNDIDADE ALTA

folhas específicas; maior risco
de overfitting

Definir alvo → separar treino/teste → treinar → prever → avaliar

Ajuste max_depth com validação — compare treino e teste.

Random Forest estabiliza árvores com aleatoriedade e votação

Uma árvore profunda pode memorizar ruído e mudar muito com pequenas alterações nos dados.

1

BAGGING

cada árvore recebe uma amostra com reposição das linhas

2

FEATURE BAGGING

cada nó testa apenas um subconjunto aleatório de atributos

3

AGREGAÇÃO

classificação: voto majoritário • regressão: média

Erros individuais tendem a se cancelar; o padrão compartilhado pelas árvores se reforça.

Logística e SVM constroem fronteiras de decisão de modos diferentes

REGRESSÃO LOGÍSTICA

$$z = w \cdot x + b$$

$$p = 1 / (1 + e^{-z})$$

- transforma a combinação linear em probabilidade
- usa um limiar, geralmente 0,5
- produz uma fronteira interpretável

Apesar do nome, é um classificador.

SUPPORT VECTOR MACHINE

Busca o hiperplano que separa as classes com a maior margem possível.

- vetores de suporte: pontos mais próximos da fronteira
- kernel trick: cria fronteiras não lineares
- funciona bem em alta dimensionalidade

A margem é o critério central.

Naive Bayes escolhe a classe com maior probabilidade

A suposição “naive”: as variáveis são condicionalmente independentes dentro de cada classe.

EXEMPLO: filtro de spam

$P(\text{spam}) = 0,40$
 $P(\text{promoção} \mid \text{spam}) = 0,70$
 $P(\text{grátis} \mid \text{spam}) = 0,60$

Pontuação spam
 $0,40 \times 0,70 \times 0,60 = 0,168$

COMPARAÇÃO

$P(\text{não spam}) = 0,60$
 $P(\text{promoção} \mid \text{não spam}) = 0,10$
 $P(\text{grátis} \mid \text{não spam}) = 0,05$

Pontuação não spam
 $0,60 \times 0,10 \times 0,05 = 0,003$

$0,168 \gg 0,003 \rightarrow \text{classificar como SPAM}$

PARTE 2


Mão na Massa



Dinâmica da Árvore de Decisão

PARTE 3

Mão na Massa - Código



<https://encurtador.com.br/QpFh>

PARTE 5

Mão na Massa

Kahoot



PARTE 5

Mão na Massa

Gabarito do código

<https://colab.research.google.com/drive/1pOpTy3uA4r1KiL8wJgJPqVmiHl471LQg?usp=sharing>

Dúvidas? Me chama.

Profª Dra. Crishna Irion

crishna.irion@prof.inteli.edu.br

