

Liderança - Módulo 03

Vieses Cognitivos e Decisões em IA

Prof^a Dr^a Camila Naves Arantes

Tempo para a Daily!



15 minutos

o que fiz, o que vou fazer, o que está me
travando. Vamos lá

Agenda



Daily Meeting + acordos 20 min

Objetivos e competências de liderança 5 min

Aquecimento: você confia no seu cérebro? 15 min

Conceituação: vieses cognitivos 15 min

Do cérebro para a máquina: viés em IA 20 min

Atividade: Máquina Moral 25 min

Aplicação no projeto + fechamento 15 min



Camila N. Arantes

EDUCAÇÃO



- Doutorado, Administração – UNINOVE
- Universidade da Cidade de Dublin
- MSc, Inovação Tecnológica – UFTM
- Advogado – Direito Digital, PI & Inovação
- Comissão de Direito de Startups OAB/MG
- MBA – Gestão de Projetos e Metodologias Ágeis
- MBA – Transformação Digital
- MBA – Dados e IA para negócios (em andamento)

O QUE EU JÁ FIZ

- Coordenei a Agência de Inovação UFTM, o escritório de transferência de tecnologia de uma universidade federal
- Liderei a primeira Chamada de Inovação Aberta da Uberaba, financiada pela FAPEMIG
- R\$500k+ em financiamento para pesquisa garantido
- Dois livros sobre direito e tecnologia; artigos em EGEPE, AOM, CARMA, SINGEP, Triple Helix e muitos outros periódicos

Nossos combinados e Participação



Pontualidade importa

Respeito pelo seu professor, pelo seu grupo e pelo próprio processo.

Colabore com empatia

Ajude e escute. Crescemos juntos.

Mantenha o autoestudo em dia

Chegue preparado para todas as sessões.

Esteja ativamente presente

Sem distrações. Mantenha o foco no momento.

Reaja no Slack

Um emoji de "positivo" (**thumbs-up**) ajuda na comunicação e no engajamento.

Horário de atendimento (Office hours)

Tempo de autoestudo, tempo de desenvolvimento ou mediante agendamento.

Slack durante o horário comercial.

Proibido comer no estúdio

Mantenha o espaço limpo e utilizável para todos.

Como sua participação é avaliada?



Faça a aula acontecer

Mande suas dúvidas e comentários construtivos durante as explicações. A sua dúvida pode ser a de um colega!

Mostre que o autoestudo tá em dia

Mande bem nos testes de conteúdo para demonstrar que você leu e entendeu o material prévio.

Chegue preparado para tirar dúvidas

Nas sessões de autoestudo ou DEV, traga questionamentos que mostrem que você já deu aquela pesquisada no assunto.

Entre de cabeça nos debates

Compartilhe sua visão e discuta os casos práticos apresentados na aula.

Divida o conhecimento com a galera

Achou um artigo, vídeo ou ferramenta bacana sobre o assunto? Compartilhe com a turma! Todo mundo cresce junto.

HORÁRIOS DE ATENDIMENTO

A professora tem horários reservados para atender os alunos

Os horários são agendados a pedido

Mande uma mensagem para combinar dia e hora

E-MAIL E SLACK

Dúvidas podem ser enviadas a qualquer momento

Use o e-mail ou o Slack

As respostas acontecem na primeira oportunidade disponível

Dica: não deixe a dúvida acumular! Quanto antes você perguntar, melhor.

Objetivos de aprendizagem

ONDE QUEREMOS CHEGAR



Reconhecer que percepção e julgamento humanos são sistematicamente enviesados, inclusive os seus.

Explicar como vieses humanos migram para sistemas de IA pelos dados, pelo algoritmo e pela interação.

Analisar casos reais de viés algorítmico e propor estratégias de mitigação e redução de danos.

Aplicar uma auditoria de vieses aos dados do seu projeto, formulando hipóteses testáveis.

Competências trabalhadas hoje



Autoconhecimento

Perceber, nomear e gerir os próprios vieses e julgamentos automáticos.

Pensamento crítico

Questionar informações; desenhar e monitorar experimentos para testar hipóteses.

Cidadania global

Refletir e agir de forma ética, considerando o impacto da tecnologia sobre pessoas.

AQUECIMENTO

Você confia no seu cérebro?

Vamos fazer um teste. Preste MUITA atenção.



~50%

das pessoas NÃO veem o gorilla atravessar a cena por 9 segundos.

Cegueira por desatenção

Quando focamos numa tarefa (contar passes), deixamos de perceber o inesperado, mesmo que esteja no centro da tela.

o que estamos deixando de ver nos nossos dados porque não estamos procurando?

Viés cognitivo: o atalho que erra sempre igual



Viés = desvio sistemático (não aleatório) de julgamento, que leva a conclusões distorcidas de forma previsível.

Modelos de IA aprendem com dados gerados por decisões humanas enviesadas (contratações, crédito, policiamento)

SISTEMA 1

rápido, automático, intuitivo

- Reconhecer um rosto
- Completar “pão com...”
- Dirigir num caminho conhecido
- Julgamentos instantâneos
- Onde moram os vieses

O viés que era individual e intuitivo vira sistemático e em escala, é o Sistema 1 da humanidade "congelado" em código.

SISTEMA 2

lento, deliberado, analítico

- Calcular 17×24
- Comparar dois modelos de dados
- Preencher um formulário
- Checar uma intuição
- Custa esforço — e é preguiçoso

Há a tentação de achar que o algoritmo é "racional e neutro" porque calcula, mas ele pode ser um Sistema 1 estatístico muito veloz, sem a deliberação crítica do Sistema 2.

O humano que usa a IA tende a aceitar a saída da máquina sem verificar... o Sistema 2 preguiçoso de novo, agora terceirizando para o software

Viés cognitivo: o atalho que erra sempre igual



Viés = desvio sistemático (não aleatório) de julgamento, que leva a conclusões distorcidas de forma previsível.

SISTEMA 1

SISTEMA 2

A IA não elimina o Sistema 1,
ela o industrializa.
O papel do líder é ser o
Sistema 2 da organização:
auditar, questionar,
desacelerar quando necessário

Conversem e preparem uma resposta




- 1 O que é um viés e por que ele não é um erro aleatório?
- 2 Como um viés entra num processo de machine learning?
- 3 Escolham um caso do texto de autoestudo (Ética e Inteligência Artificial) com efeito indesejado de modelo preditivo: como vocês o evitariam?
- 4 Qual a diferença entre viés e (in)justiça: bias e fairness?

A IA aprende com o nosso mundo

inclusive com o pior dele



ciclo de retroalimentação: o viés volta para os próximos dados



Por onde o viés entra num sistema de IA

DO CÉREBRO PARA A MÁQUINA



Viés de dados

Amostragem torta, grupos sub-representados, rótulos herdados de decisões humanas passadas, medição por proxy (ex.: CEP no lugar de renda).

Viés algorítmico

Escolhas de modelagem: função objetivo, variáveis usadas, limiares de corte, cada escolha embute valores.

Viés de interação

O sistema aprende com o uso: cliques, feedback e câmaras de eco realimentam e amplificam padrões.

Quando o algoritmo não vê você




How I'm fighting bias in algorithms

Pesquisadora do MIT mostra ao vivo um software de visão computacional que não detecta o rosto dela, até ela vestir uma máscara branca.

Ela chama isso de coded gaze: o olhar de quem programou embutido na máquina.

[youtube.com/watch?v=UG_X_7q63rY](https://www.youtube.com/watch?v=UG_X_7q63rY)

Gender Shades: o erro não é igual para todos



34,7%

de erro na classificação de gênero para mulheres de pele escura, contra 0,8% para homens de pele clara, nos sistemas comerciais auditados (IBM, Microsoft, Face++).

Causa central: bases de treino dominadas por rostos claros e masculinos.

ESTUDO DE REFERÊNCIA · BUOLAMWINI & GEBRU, 2018

Buolamwini, J. & Gebru, T. (2018). Gender Shades. Proceedings of Machine Learning Research, 81, 1-15. Valores: piores taxas de erro entre os 3 sistemas.

Isso já decidiu a vida de muita gente



COMPAS Justiça (EUA)

Algoritmo de risco de reincidência usado por juízes: réus negros eram quase 2x mais rotulados erroneamente como 'alto risco' do que réus brancos.

ProPublica, 2016

Amazon Recrutamento

IA treinada com 10 anos de currículos aprovados aprendeu a penalizar currículos com a palavra "women's". O projeto foi descontinuado em 2018.

Reuters, 2018

Em comum: ninguém programou o preconceito, ele veio pelos dados históricos.


Máquina Moral (MIT)



**O carro autônomo precisa decidir.
E vocês decidem por ele.**

1. Acessem em grupo: moralmachine.net
2. Para cada cenário, cheguem a CONSENSO, votar não vale, é preciso argumentar.
3. Atenção aos detalhes das imagens: quem são as pessoas?
4. Ao final, comparem seus resultados com os da população geral.

***Anotem: em qual cenário o grupo mais travou?
Por quê?***



O que a Máquina Moral revelou sobre nós?



Como o resultado do grupo se compara ao da população geral?

Quais detalhes das imagens pesaram nas decisões, idade, gênero, aparência, status? Isso é critério ou viés?

Onde o consenso foi difícil? O que isso diz sobre programar ética em código?

Se cada cultura decide diferente (estudo em 233 países), de quem devem ser os valores embutidos no algoritmo?

Auditoria de vieses na base do parceiro



Representação

Quem aparece nos dados, e quem está faltando? A amostra cobre todas as personas afetadas?

Origem

Como e por quem os dados foram coletados? Que decisões humanas passadas eles congelam?

Proxies

Alguma variável 'inocente' pode carregar um atributo sensível escondido?

Experimento

Que teste simples confirmaria ou refutaria a hipótese de viés? (comparar grupos, reamostrar, remover variável)

Atingimos nossos objetivos?



- ☐ Reconhecer que nosso julgamento é sistematicamente enviesado
- ☐ Explicar como o viés humano migra para a IA
- ☐ Analisar casos reais e estratégias de mitigação
- ☐ Aplicar a auditoria de vieses ao projeto

"O design de qualquer tecnologia é um ato moral."

Luciano Floridi, 2023



Prof^a Dr^a Camila Naves Arantes

camila.arantes@prof.inteli.edu.br

Próximo encontro (Semana 07): Feedback em projetos