

Estatística Indutiva - Estimação Intervalar e Teste de Hipóteses

Prof. Geraldo Magela Severino Vasconcelos
Ago/2026



1. Planejamento e Rotinas Iniciais

1.1. Instruções do Módulo

1.2. Desafio (08:00-08:45)

1.3. Autoestudos no ateliê (08:45-10:00)

1.4. Daily Meeting (10:00-10:15)

2. Instrução de Hoje

2.1. Aplicação aos projetos (10:15-10:20)

2.2. O Teorema do Limite Central
(10:20-10:35)

2.3. Intervalos de Confiança (10:35-11:05)

2.4. Fundamentos do Teste de Hipóteses
(11:05-11:30)

2.5. Teste Z e Teste T (11:30-12:00)

3. Encerramento

3.1. Recomendações para casa

3.2. Feedback da Instrução

Clique em um título acima para navegar e em  **Índice** para voltar.



1. Planejamento e Rotinas Iniciais



Índice

1.1. Instruções do Módulo

1.1. Instruções do Módulo

Planejamento:

- Semana 2: Distribuições de Probabilidade **FA**
- Semana 3: Estatística Indutiva - Estimação Intervalar e Teste de Hipóteses **FA**
- Semana 4: Definição de função de várias variáveis e representação gráfica **FT**
- Semana 5: Derivadas Parciais **FT**
- Semana 6: Integral Múltipla **FT**
- Semana 8: Transformações lineares **FA**



FT Frente transversal (semanas 4, 5 e 6): conecta todos os módulos do primeiro ano.

FA Frente aplicada (semanas 2, 3 e 8): aplicação mais imediata ao projeto.

1.1. Instruções do Módulo

Calendário 2026.2A:



Sem	Datas	Seg	Ter	Qua	Qui	Sex
1	Ago 03-07				ES11.T13: manhã	
2	Ago 10-14		IN03.T26: manhã IN03.T26: tarde	IN03.T29: manhã IN03.T29: tarde		
3	Ago 17-21		IN03.T29: manhã IN03.T29: tarde	ES11.T13: manhã	IN03.T26: manhã IN03.T26: tarde	
4	Ago 24-28		IN03.T29: manhã IN03.T29: tarde	IN03.T26: manhã		
5	Ago 31- Set 04		IN03.T29: manhã IN03.T29: tarde	IN03.T26: manhã	ES11.T13: manhã	
6	Set 07-11		IN03.T26: manhã IN03.T26: tarde	IN03.T29: manhã		
7	Set 14-18		ES11.T13: manhã			
8	Set 21-25		IN03.T29: manhã IN03.T29: tarde	IN03.T26: manhã		
9	Set 28- Out 02					
10	Out 05-09					

1.2. Desafio (08:00-08:45)

1.2. Desafio de Matemática (08:00-08:45)

Desafio de Matemática e Física

- Sobre a mesa: apenas **caneta**, **lapiseira**, **borracha** e o **desafio**.
- **Individual** e **sem consulta**.
- Valor: **dois pontos** na Adalove.
- Duração: **45 minutos**.
- No papel; use **caneta** (lápis só no rascunho).
- Após terminar, mova seu card para **feito** na **Adalove**.



Bom trabalho!

1.3. Autoestudos no ateliê (08:45-10:00)

1.3. Autoestudos: Informações (1)

1. A pedido dos alunos, para cada tema de Matemática e Física, pelo menos três cards estão disponíveis na Adalove:

a) Card de capítulo do livro;



b) Card de videoaula;

- preferencialmente da UNIVESP, uma faculdade pública de alta qualidade, voltada ao ensino remoto;
- **alternativa opcional** ao capítulo do livro (não é preciso estudar ambos).

c) Card de exercícios resolvidos:

- **altamente recomendados** - ajudam muito na aprendizagem;
- tente resolvê-los sozinho antes de conferir as respostas.

$$\begin{aligned} 1. f(x) &= x^3 + x - \sqrt{x+1} \\ 2. f(x) &= x^{1/3} + \frac{1}{\sqrt{x^2+8}} \\ 3. f(x) &= (x^{100}-1)\left(x^{7/2}-\sqrt{4x^3-1}+\frac{1}{x^5}\right) \\ 4. f(x) &= \frac{x^{13}+(50x^2-x^{36}-0.002)^2}{x^{80}+x^7-1000} \\ 5. f(x) &= \sin\left(\frac{x}{\sqrt{x^2+8}}\right) - \cos^4(\sqrt{x^2+8}) \end{aligned}$$

1.3. Autoestudos: Informações (2)

2. Cada encontro de instrução pode incluir breves revisões do conteúdo de autoestudo.
- a) Esta revisão é excepcional e complementar e **não substitui** o autoestudo;
 - b) No nosso modelo de sala invertida, é **essencial** que todos os alunos **concluam o autoestudo antes** do encontro de instrução.



3. Devido a limitações de tempo, nem todos os tópicos do autoestudo serão abordados durante o encontro.
- a) Todos os tópicos podem ser cobrados em avaliações.
 - b) **Dúvidas** sobre qualquer parte do autoestudo podem ser esclarecidas com o professor.

1.3. Autoestudos: Cards desta semana

- **Desafio de Matemática 1**

- Estimação pontual e intervalar - Videoaula
- Teste de hipóteses - Videoaula

- **Opcional:** Estimação pontual e intervalar - Livro
- **Opcional:** Teste de hipóteses - Livro

- **Opcional:** Estimação pontual e intervalar - Exercícios Resolvidos em videoaula
- **Opcional:** Teste de hipóteses - Exercícios resolvidos em videoaula

- **Optional (English):** Confidence intervals - Book chapter
- **Optional (English):** Hypothesis testing - Book chapter



1.4. Daily Meeting (10:00-10:15)



Índice

1.4. Daily Meeting

Daily Meeting – 10:00-10:15

- O que fiz de ontem para hoje?
- O que aprendi de ontem para hoje?
- O que planejei fazer de hoje para amanhã?
- Tenho algum impedimento?





inteli
INTELETO E INOVAÇÃO
EM POLÍTICAS TECNOLÓGICAS
IPT

inteli


2. Instrução de Hoje

Referências Principais

- Illowsky, B.; Dean, S. L. **Introductory Statistics 2e**, 2nd Edition. Houston: Rice University, 2025. ISBN 9781961584327.

[Chapter 8. Confidence Intervals](#)

[Chapter 9. Hypothesis Testing](#)



Referências Principais

- Kravets, Z. **Elementary Statistics**. Mission College.
[Chapter 8. Hypothesis Testing with One Sample](#)



Referências Principais

- Bussab, W. O., Morettin, P. A.; [Estatística Básica](#), 10. ed. São Paulo: Saraiva Uni, 2023. ISBN 9788571441484. Sections 11.1, 11.6, 12.1-12.5, and 12.8.



2. Instrução de Hoje

Conteúdo em Inglês

- Inglês é o **idioma padrão** da Tecnologia.
- Entendê-lo é essencial para a sua **vida profissional**.



- Parte do nosso material será em inglês, como parte da preparação profissional de todos.
- A principal preocupação é a formação e a empregabilidade de quem ainda está aprendendo.
- O Inteli oferece **curso gratuito de inglês**. Aproveite esse recurso.

Aprender faz parte do processo. Em caso de dúvidas, pergunte sempre.

2. Instrução de Hoje

Aprendizado Ativo

- Esta apresentação contém slides teóricos, com um breve resumo.
 - Referência rápida para esclarecer dúvidas durante o encontro e ajudar nos autoestudos.
 - Estes slides **não serão seguidos** durante o encontro de instrução.
 - No encontro, os alunos serão convidados a explicar alguns conceitos, e em seguida passaremos às atividades.
- Lembre-se, você é responsável pelo **seu próprio aprendizado**.



2.1. Aplicação aos projetos (10:15-10:20)

2.1. Aplicação aos projetos

Turma 24: Saúde Suplementar

- Modelo preditivo para estimar demanda de pacientes por serviços especializados, cruzando dados históricos e demográficos.



- Faixas de internação:** Estimar intervalos prováveis de pacientes diários em vez de valores únicos.
- Margens de segurança:** Definir limites esperados para a ocupação de leitos de alta complexidade.
- Validação de políticas:** Medir se novos protocolos de triagem produzem mudanças significativas na demanda.
- Comparação de grupos:** Testar se o volume de exames solicitados difere de forma relevante entre as estações.

2.1. Aplicação aos projetos

Turma 25: Proteína Animal

- Modelos preditivos que conectam a produção mensal de proteína animal à demanda por ração e macroingredientes.
-
- a) **Faixas de consumo:** Estimar intervalos de confiança para a demanda de ração por lote de aves.
 - b) **Incerteza de produção:** Definir bandas de probabilidade para o rendimento mensal de carne bovina.
 - c) **Impacto nutricional:** Confirmar se a mudança de ingredientes gera ganho de peso estatisticamente válido.
 - d) **Comparação de desempenho:** Avaliar se a eficiência produtiva difere de maneira significativa entre galpões.



2.1. Aplicação aos projetos

Turma 26: Vendas de Veículos

- Ferramenta de predição mensal das vendas de veículos por segmento e motorização, cruzando indicadores macroeconômicos.



- Faixas de venda:** Estimar intervalos de volume comercializado para suportar margens de estoque.
- Incerteza de ticket:** Definir os limites de segurança esperados para a previsão do ticket médio mensal.
- Sensibilidade de mercado:** Mensurar se variações na taxa de juros alteram significativamente a demanda.
- Validação de tendências:** Confirmar se o interesse por modelos elétricos já supera os veículos a combustão.

2.1. Aplicação aos projetos

Turma 27: Óleo Diesel Agrícola

- Inteligência artificial para prever o consumo futuro e o momento ideal de compra de óleo diesel por produtores rurais.
-
- a) **Faixas de consumo:** Definir limites esperados de gasto de combustível durante o pico do plantio.
 - b) **Janelas de compra:** Estimar intervalos de tempo prováveis até a necessidade do próximo reabastecimento.
 - c) **Validação de variáveis:** Avaliar se o tipo de solo impacta o consumo de combustível de forma relevante.
 - d) **Efeito climático:** Medir se chuvas intensas produzem mudanças significativas no rendimento dos tratores.



2.1. Aplicação aos projetos

Turma 28: Detratores de NPS

- Modelo de classificação para antecipar a probabilidade de passageiros avaliarem negativamente a experiência da viagem.



- a) Intervalos de nota: Estimar faixas de pontuação esperadas na abertura de novas rotas operacionais.
- b) Proporção de risco: Definir bandas de probabilidade para o volume de passageiros insatisfeitos no mês.
- c) Impacto de falhas: Confirmar se atrasos operacionais reduzem a satisfação média de forma estatística.
- d) Validação de serviço: Avaliar se a renovação da frota eleva as pontuações em níveis significativos.

2.1. Aplicação aos projetos

Turma 29: Previsão Térmica

- Modelo preditivo para estimar a temperatura de fogões com alta precisão utilizando históricos de simulação numérica.
-
- a) **Faixas de temperatura:** Estimar limites térmicos esperados nas superfícies em vez de um único grau.
 - b) **Confiabilidade preditiva:** Definir a margem de erro da simulação em relação à variabilidade dos dados.
 - c) **Avaliação de modelo:** Confirmar se os resultados preditivos da IA se alinham aos testes físicos de bancada.
 - d) **Comparação de materiais:** Testar se o novo isolante térmico reduz o calor externo de forma estatisticamente válida.



2.2. O Teorema do Limite Central (10:20-10:35)

2.2.1. Teoria e Contexto do Projeto



2.2.1. O Teorema do Limite Central (TLC)



PARA AUTOESTUDO

O **Teorema do Limite Central** é um dos conceitos mais poderosos da estatística, permitindo-nos fazer inferências sobre uma população mesmo quando sua distribuição é desconhecida.

- **Distribuição Amostral da Média:** Imagine extrair múltiplas amostras aleatórias de tamanho n de uma população e calcular a média ($\bar{x}$) para cada amostra. A distribuição dessas médias amostrais é chamada de distribuição amostral.
- **O Princípio Central do TLC:** Independentemente da forma da distribuição populacional original (assimétrica, uniforme, etc.), a distribuição amostral da média se **aproximará de uma Distribuição Normal** à medida que o tamanho da amostra n aumentar (geralmente $n \geq 30$).

2.2.1. O Teorema do Limite Central (TLC)

PARA AUTOESTUDO



2.2.1. Erro Padrão da Média

MEMORIZE

A distribuição amostral da média tem suas próprias propriedades, derivadas diretamente dos parâmetros populacionais originais (μ e σ).

- **Média das Médias Amostrais:**

A média de todas as médias amostrais é igual à média populacional verdadeira.

$$\mu_{\bar{x}} = \mu$$

PARA AUTOESTUDO

- **Erro Padrão (EP):**

O desvio padrão das médias amostrais diminui à medida que o tamanho da amostra n aumenta.

$$\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}}$$


Quanto maior o tamanho da amostra n , mais estreita a distribuição amostral, de forma que a média amostral $\bar{x}$ se torna uma estimativa mais precisa da verdadeira média populacional μ .

2.2.1. Contexto do Projeto

Principais Conclusões: Os erros de predição da IA em instâncias individuais costumam ser altamente assimétricos e não normais. O **Teorema do Limite Central** garante que o **erro médio de grandes lotes** seguirá uma curva normal.

Em nosso Modelo Preditivo de IA:

- **Avaliação em Lotes:** Usamos lotes (ex: $n = 50$) em vez de predições únicas para avaliar o desempenho da IA, em vez de predições únicas. O TLC permite o uso de ferramentas de Distribuição Normal (como testes Z) nas médias dos lotes, mesmo que os erros individuais sejam mal comportados.
- **Reduzindo a Volatilidade:** A fórmula do Erro Padrão ($\sigma / \sqrt{n}$) prova por que aumentar o tamanho do conjunto de teste torna a métrica de avaliação da IA muito mais estável e confiável.



2.2.2. Atividades



2.2.2. Erro Padrão

ATIVIDADE 1

Cenário:

Sua equipe implantou um modelo de IA para prever o consumo diário de recursos. A análise histórica de erros de predição individuais revela uma distribuição não normal e altamente assimétrica, com um desvio padrão populacional conhecido de 14 unidades.

Para validar a estabilidade do modelo em produção, a equipe de IA coleta um lote de avaliação aleatório de 49 predições e calcula o erro médio desse lote específico.

Tarefa:

Calcule o **Erro Padrão da Média (EP)** para este lote de avaliação.

Você pode usar uma calculadora.

2.2.3. Respostas



2.2.3. Atividade 1: Resposta

ATIVIDADE 1

RESPOSTA

Conhecemos o desvio padrão populacional (σ) e o tamanho da amostra (n): $\sigma = 14$, $n = 49$

Aplicando a fórmula do Erro Padrão:

$$\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}} = \frac{14}{\sqrt{49}} = \frac{14}{7}$$

$$\sigma_{\bar{x}} = 2$$

Decisão de Negócios da IA: Embora as previsões individuais flutuem bastante em 14 unidades, ao avaliar lotes de 49, a variabilidade da métrica média diminui para **apenas 2 unidades**. A distribuição dessas médias de lote forma um sino gaussiano previsível, permitindo que a equipe aplique intervalos de confiança.

2.3. Intervalos de Confiança (10:35-11:05)

2.3.1. Teoria e Contexto do Projeto



2.3.1. Estimativas Pontuais vs. Intervalares

PARA AUTOESTUDO

Uma média amostral fornece um único valor como estimativa da média populacional, mas raramente corresponde perfeitamente ao parâmetro verdadeiro. Usamos intervalos para expressar incerteza.

- **Estimativa Pontual:** Um único número usado para estimar um parâmetro populacional (ex., média amostral $\bar{x}$ estimando a média populacional μ).
- **Estimativa Intervalar (Intervalo de Confiança):** Um intervalo de valores, derivado da estatística da amostra, que provavelmente contém o verdadeiro parâmetro populacional.
- **Nível de Confiança ($1 - \alpha$):** A probabilidade de que a metodologia de intervalo capture o verdadeiro parâmetro se o experimento for repetido muitas vezes (comumente 90%, 95% ou 99%).

2.3.1. Derivando a Margem de Erro

Queremos uma estimativa intervalar da média populacional μ .

PARA AUTOESTUDO

Ela é derivada da fórmula do escore Z aplicada à Distribuição Amostral da Média.

- **Limite inferior:** $Z_{\alpha/2} = \frac{\bar{x} - \mu}{\frac{\sigma}{\sqrt{n}}} \Rightarrow Z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}} = \bar{x} - \mu \Rightarrow \bar{x} - \mu = Z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}} \Rightarrow$

$$\Rightarrow -\mu = Z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}} - \bar{x} \Rightarrow \mu = \bar{x} - Z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}$$

- **Limite superior:** $-Z_{\alpha/2} = \frac{\bar{x} - \mu}{\frac{\sigma}{\sqrt{n}}} \Rightarrow -Z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}} = \bar{x} - \mu \Rightarrow \mu = \bar{x} + Z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}$

- **Intervalo:** $\bar{x} - Z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{x} + Z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}$

2.3.1. Calculando Intervalos de Confiança

MEMORIZE

Quando o desvio padrão populacional (σ) é conhecido OU o a amostra é suficientemente grande ($n \geq 30$), construímos o Intervalo de Confiança usando a Distribuição Normal (valores Z).


- **Margem de Erro (E):** Diferença máxima esperada entre a estimativa pontual e o parâmetro verdadeiro.

$$E = Z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}$$

- **Limites do Intervalo de Confiança:**

$$\bar{x} - E \leq \mu \leq \bar{x} + E$$

PARA AUTOESTUDO



2.3.1. Cálculo do Tamanho da Amostra

PARA AUTOESTUDO

Podemos rearranjar as fórmulas da Margem de Erro para calcular o **tamanho mínimo da amostra (n)** necessário para alcançar uma precisão específica antes de iniciar um experimento.

$$E = Z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}} \Rightarrow \sqrt{n} = Z_{\alpha/2} \cdot \frac{\sigma}{E} \Rightarrow n = \left(\frac{Z_{\alpha/2} \cdot \sigma}{E} \right)^2$$

- **Para Variáveis Contínuas (Médias):** Ao estimar uma média com um desvio padrão conhecido (σ) e uma margem de erro desejada (E):

$$n = \left(\frac{Z_{\alpha/2} \cdot \sigma}{E} \right)^2$$

2.3.1. No Projeto: Estimando o Desempenho da IA

Principais Conclusões: Uma métrica única (como uma precisão de 85% ou um erro médio de 12 unidades) avaliada em um conjunto de teste é apenas uma **estimativa pontual**. Como os conjuntos de teste são amostras, eles carregam aleatoriedade.

Em nosso Modelo Preditivo de IA:

- **Implantando com Confiança:** Em vez de afirmar “a IA tem um erro de 12”, os cientistas de dados usam Intervalos de Confiança: *“Temos 95% de confiança de que o verdadeiro erro de produção cairá entre 10,5 e 13,5.”*
- **Dimensionando o Conjunto de Teste:** Para testar a IA, usamos a fórmula do tamanho da amostra para responder: *“Quantas previsões precisamos testar para garantir a precisão da IA dentro de uma margem de erro de 2%?”*



2.3.2. Atividades



2.3.2. Calculando Intervalos de Confiança

ATIVIDADE 2

Cenário:

Você está avaliando um novo modelo de regressão de IA para prever o consumo de combustível. Você executa o modelo em um conjunto de teste de 100 amostras.

O erro médio de predição desta amostra foi de **12 unidades**. A partir de dados históricos de algoritmos similares, você sabe que o desvio padrão populacional dos erros é de 4 unidades.

Tarefa: Calcule o Intervalo de Confiança para o verdadeiro erro médio de predição do modelo de IA para dois níveis de confiança diferentes:

- a) Intervalo de Confiança de 95% b) Intervalo de Confiança de 98%

- Use o seguinte aplicativo para verificar os valores de $Z_{\alpha/2}$:

<https://www.mathsisfun.com/data/standard-normal-distribution-table.html>

ATIVIDADE 3

Cenário:

A equipe de IA está preparando um novo modelo de regressão para prever tempos de resposta de sensores. As partes interessadas exigem precisão extremamente alta na fase de avaliação.

A equipe de engenharia quer que a margem de erro do tempo médio de resposta seja de no máximo 1 milissegundo. A partir de dados históricos, sabe-se que o desvio padrão populacional é de 5 milissegundos.

Tarefa: Calcule o número mínimo de amostras de teste necessário para garantir esta margem de erro com um nível de confiança de 99%.

Para um nível de confiança de 99%, a área cumulativa é 0,9950. O valor Z correspondente é $Z_{\alpha/2} = 2,576$.

2.3.3. Respostas



2.3.3. Atividade 2a: Resposta (Confiança de 95%)

ATIVIDADE 2a

RESPOSTA

Passo 1: Encontrar $Z_{\alpha/2}$ usando o aplicativo

Um nível de confiança de 95% deixa 5% para as caudas ($\alpha = 0.05$). Isso significa que 2,5% está na cauda superior.

Para usar um aplicativo Z cumulativo, procuramos a área até aquele ponto: $95\% + 2.5\% = 97.5\%$ (ou **0.9750**). Procurar 0,9750 dá **$Z = 1,96$** .

Passo 2: Calcular a Margem de Erro (E)

$$\begin{aligned} E &= Z \cdot \frac{\sigma}{\sqrt{n}} = 1.96 \cdot \frac{4}{\sqrt{100}} = \\ &= 1.96 \cdot \frac{4}{10} = 1.96 \cdot 0.4 = \mathbf{0.784} \end{aligned}$$

Passo 3: Construir o Intervalo

$$\begin{aligned} \bar{x} - E &< \mu < \bar{x} + E \\ 12 - 0.784 &< \mu < 12 + 0.784 \end{aligned}$$

$$\mathbf{11.216 < \mu < 12.784}$$

Decisão de Negócios da IA: Temos 95% de confiança de que o verdadeiro erro médio de predição deste modelo de IA em produção estará entre 11,216 e 12,784 unidades.

2.3.3. Atividade 2b: Resposta (Confiança de 98%)

ATIVIDADE 2b

RESPOSTA

Passo 1: Encontrar $Z_{\alpha/2}$ usando o aplicativo

Um nível de confiança de 98% deixa 2% para as caudas ($\alpha = 0.02$). Isso significa que 1% está na cauda superior.

Para usar um aplicativo Z cumulativo, procuramos a área até aquele ponto: 98% + 1% = 99% (ou **0.9900**). Procurar 0,9900 dá $Z = 2,33$.

Passo 2: Calcular a Margem de Erro (E)

$$\begin{aligned} E &= Z \cdot \frac{\sigma}{\sqrt{n}} = 2.33 \cdot \frac{4}{\sqrt{100}} = \\ &= 2.33 \cdot \frac{4}{10} = 2.33 \cdot 0.4 = \mathbf{0.932} \end{aligned}$$

Passo 3: Construir o Intervalo

$$\begin{aligned} \bar{x} - E &< \mu < \bar{x} + E \\ 12 - 0.932 &< \mu < 12 + 0.932 \end{aligned}$$

$$\mathbf{11.068 < \mu < 12.932}$$

Conclusão Estatística: Para termos *mais confiança* (98% vs 95%) de que capturamos a verdadeira média, devemos permitir um **intervalo mais amplo** (margem de erro maior: 0,932 vs 0,784).

2.3.3. Atividade 3: Resposta

ATIVIDADE 3

RESPOSTA

Identificamos as variáveis para um cálculo de tamanho de amostra de média contínua: $Z = 2.576$, $E = 1$, $\sigma = 5$.

Aplicar a fórmula do Tamanho da Amostra para Médias

$$n = \left(\frac{Z \cdot \sigma}{E} \right)^2 = \left(\frac{2.576 \cdot 5}{1} \right)^2 = (12.88)^2 \Rightarrow \boxed{n = 165.89}$$

Decisão de Negócios da IA: Como não podemos testar uma fração de amostra, sempre **arredondamos para cima** para garantir que a restrição da margem de erro seja estritamente atendida. A equipe deve coletar um conjunto de teste de **pelo menos 166 amostras** para garantir uma margem de erro de 1 ms com 99% de confiança.

2.4. Fundamentos do Teste de Hipóteses (11:05-11:30)



Índice

2.4.1. Teoria e Contexto do Projeto



2.4.1. Hipóteses Nula e Alternativa

PARA AUTOESTUDO

O teste de hipóteses é um procedimento formal para determinar se há evidência estatística suficiente para rejeitar uma suposição padrão.

- **Hipótese Nula (H_0):** A suposição base ou status quo. Ela afirma que **não há mudança** e inclui a igualdade (=). Sempre testamos *contra* H_0 .
- **Hipótese Alternativa (H_a ou H_1):** A afirmação que estamos tentando provar. Ela contradiz a hipótese nula e elas são complementares.
 - **Teste Bilateral (Bicaudal):** Testa se um parâmetro é *diferente* de um valor (seja maior ou menor, $\neq$).
 - **Teste Unilateral (Unicaudal):** Testa se um parâmetro é especificamente *maior que* ($>$) ou *menor que* ($<$) um valor .

2.4.1. Erros do Tipo I e Tipo II

PARA AUTOESTUDO

Como dependemos de dados de amostra, nossa decisão pode estar errada.

Existem dois tipos distintos de erros que podemos cometer.

- **Erro do Tipo I (Falso Positivo):**

Rejeitar H_0 quando ela é verdadeira. A probabilidade desse erro é denotada por α (o **nível de significância**).

- **Erro do Tipo II (Falso Negativo):**

Falhar em rejeitar H_0 quando ela é falsa. A probabilidade desse erro é denotada por β .

		Our Decision	
		Fail to Reject H_0	Reject H_0
Actual Truth	H_0 is True (No Effect)	Correct Decision (True Negative) <i>Prob = $1 - \alpha$</i>	Type I Error (False Positive) <i>Prob = α (Significance)</i>
	H_0 is False (Effect Exists)	Type II Error (False Negative) <i>Prob = β</i>	Correct Decision (True Positive / Power) <i>Prob = $1 - \beta$</i>

Poder Estatístico ($1 - \beta$): A probabilidade de rejeitar corretamente uma hipótese nula falsa.


A hipótese nula é rejeitada ou não rejeitada, mas nunca aceita.

2.4.1. Contexto do Projeto: Testando Modelos de IA

Principais Conclusões: Em ambientes de produção, não implantamos um novo modelo de IA apenas porque ele teve um desempenho ligeiramente melhor em um conjunto de teste. Usamos o Teste de Hipóteses para provar que a melhoria é **estatisticamente significativa**.

Em nosso Modelo Preditivo de IA:

- **O Status Quo (H_0):** Ao desenvolver uma Versão 2 (V2) de um modelo de IA, a suposição padrão é que H_0 : V2 não é melhor que V1. Só implantamos a V2 se encontrarmos fortes evidências (H_a) de que ela realmente melhora o desempenho.
- **Custo de Falsos Positivos:** Um erro do Tipo I significa implantar um modelo inútil. Isso incorre em custos de infraestrutura, horas de engenharia e risco operacional sem nenhum ganho real de negócios.



2.4.2. Atividades



2.4.2. Formulando Hipóteses e Erros

ATIVIDADE 4

Cenário:

Sua equipe desenvolveu uma nova arquitetura (V2) para o algoritmo de predição de IA. O algoritmo atual (V1) tem um erro médio de predição de 15 unidades.

A equipe afirma que a V2 *reduz* significativamente o erro médio de predição, tornando o sistema mais preciso. Você decide executar um teste A/B antes de substituir a V1 em produção.

Tarefas:

- Escreva a Hipótese Nula (H_0) e a Hipótese Alternativa (H_a) para este cenário específico. Este é um teste unilateral ou bilateral?
- Explique as consequências de negócios de cometer um **Erro do Tipo I** versus um **Erro do Tipo II** neste cenário de implantação de IA.

2.4.3. Respostas



ATIVIDADE 4

RESPOSTA

Resolução Analítica e Interpretação de Negócios:

a) Formulando Hipóteses:

- $H_0: \mu_{V2} \geq 15$
O erro do novo modelo é maior ou igual ao antigo (Sem melhoria).
- $H_a: \mu_{V2} < 15$
O erro do novo modelo é estritamente menor que o antigo (Existe melhoria).

Este é um teste **Unilateral (Unicaudal)** porque nos importamos apenas se o erro *diminui*, e não apenas se ele muda.

b) Consequências de Negócios:

- **Erro do Tipo I (α):**
Concluimos que V2 é melhor quando na verdade não é. **Impacto:** A empresa desperdiça dinheiro substituindo o sistema, potencialmente degradando o desempenho.
- **Erro do Tipo II (β):**
Falhamos em reconhecer que V2 é realmente melhor. **Impacto:** A empresa perde a oportunidade de melhorar o produto (Custo de Oportunidade), mantendo um modelo inferior.

2.5. Teste Z e Teste T (11:30-12:00)

2.5.1. Teoria e Contexto do Projeto



2.5.1. Quando usar o Teste Z vs. Teste T

PARA AUTOESTUDO

Para testar uma hipótese sobre a média de uma população, devemos calcular uma **Estatística de Teste**. A escolha entre um Teste Z e um Teste T depende do tamanho da amostra e se o desvio padrão populacional (σ) é conhecido.


- **O Teste Z:** Usado quando o desvio padrão populacional σ é conhecido OU quando o tamanho da amostra é grande: $n \geq 30$.
 - Com amostras grandes, o desvio padrão amostral (s) é um substituto confiável para σ .
- **O Teste T:** Usado quando σ é desconhecido E $n < 30$.
 - Neste caso, usar s introduz incerteza extra que a distribuição Z não lida adequadamente.

2.5.1. A Distribuição T de Student

PARA AUTOESTUDO

A **Distribuição T de Student** é similar à distribuição normal padrão, com **caudas mais longas**, compensando a incerteza de estimar o desvio padrão a partir de uma amostra pequena.

- **Graus de Liberdade (df):**
 - A forma da distribuição T depende inteiramente do tamanho da amostra.
 - Os graus de liberdade são calculados como $df = n - 1$.
- **Convergência:** À medida que o tamanho da amostra (n) aumenta, a distribuição T converge para a curva Normal Padrão (Z).



2.5.1. Calculando as Estatísticas de Teste

MEMORIZE

PARA AUTOESTUDO

A estatística de teste mede quantos erros padrão a média amostral ($\bar{x}$) está da média populacional hipotética (μ_0).

Score Z para Médias Amostras (Teste Z):

Usado quando σ é conhecido OU $n \geq 30$:

$$Z_{test} = \frac{\bar{x} - \mu_0}{\frac{\sigma}{\sqrt{n}}}$$

Score T para Médias Amostras (Teste T):

Usado quando σ é desconhecido E $n < 30$.

$$t_{test} = \frac{\bar{x} - \mu_0}{\frac{s}{\sqrt{n}}}$$

O Teste T usa o desvio padrão amostral (s).

2.5.1. Contexto do Projeto

Principais Conclusões: Na IA do mundo real, testar um modelo em milhares de sensores físicos ou usuários reais é caro. Frequentemente validamos melhorias de IA em **amostras pequenas** ($n < 30$), usando o **Teste T** para provar a significância estatística.

Em nosso Modelo Preditivo de IA:

- **Testes em Pequena Escala:** Antes de implantar uma nova versão de IA, a equipe a testa em uma pequena amostra de 15 ou 20 servidores. Se o Teste T rejeitar H_0 , podemos implantá-la com confiança.
- **Lidando com a Incerteza:** Como o teste é pequeno, a variância é incerta. As caudas mais longas da distribuição T impedem a comemoração prematura de uma “melhoria” que era apenas uma variação natural de desempenho.



2.5.2. Atividades



2.5.2. Atividade 5: Teste T

ATIVIDADE 5

Cenário: Uma equipe de IA afirma que a nova arquitetura do seu modelo reduz o tempo médio de processamento de inferência. O modelo antigo tinha um tempo de processamento médio de 50 milissegundos.

Para provar a afirmação, rodam o novo modelo em uma amostra de teste de 15 execuções. A média amostral é de 46 ms, com um desvio padrão amostral de 6 ms.

Tarefa:

- Defina H_0 e H_a .
- Explique por que você precisa usar o teste T e não o teste Z.
- Calcule a estatística t_{test} .
- Use a internet para procurar o valor T crítico para $\alpha = 0.05$. Compare seu t_{test} com t_{crit} e decida se H_0 deve ser rejeitado. Qual é a decisão final de negócios?

2.5.2. Atividade 6: Teste Z

ATIVIDADE 6 (OPCIONAL, PARA CASA)

Cenário: O seu modelo de IA em produção tem uma precisão média histórica de 85,0%, com um desvio padrão populacional conhecido de 4,0%.

Você implanta o modelo em uma nova cidade. Ao longo de um lote de 36 dias, a precisão média cai para 84,0%.

Tarefa:

- Defina H_0 e H_a .
- Explique por que você pode usar o teste Z.
- Calcule a estatística Z_{test} .
- Use a internet para procurar o valor Z crítico para $\alpha = 0.05$. Compare seu Z_{test} com Z_{crit} e decida se H_0 deve ser rejeitado. Qual é a decisão final de negócios?

2.5.3. Respostas



2.5.3. Atividade 5: Resposta

ATIVIDADE 5

a) Hipóteses:

$H_0 : \mu \geq 50$ (Sem redução de tempo)

$H_a : \mu < 50$ (Tempo reduzido)

b) Por que usar o Teste T?

Porque o tamanho da amostra é pequeno ($n = 15 < 30$) **E** o desvio padrão populacional (σ) é desconhecido (temos apenas o desvio padrão amostral $s = 6$).

c) Calcular a Estatística de Teste (t_{test}):

$$t_{test} = \frac{\bar{x} - \mu_0}{\frac{s}{\sqrt{n}}} = \frac{46 - 50}{\frac{6}{\sqrt{15}}} = \frac{-4}{3.873}$$

$$t_{test} = -2.58$$

RESPOSTA

d) Comparação e Decisão:

Usando a internet, para um teste unilateral (cauda à esquerda) com $\alpha = 0.05$ e **graus de liberdade** $df = 14 (n - 1)$, encontramos:

$$t_{crit} = -1.761$$

Nosso t_{test} calculado (-2.58) está mais a fundo na região crítica de rejeição do que t_{crit} (-1.761). Como $-2.58 < -1.761$, **Rejeitamos H_0** .

Decisão de Negócios da IA:

A redução no tempo de processamento é **estatisticamente significativa**, não apenas um acaso da amostra pequena. A equipe de engenharia deve implantar o novo modelo de IA.

2.5.3. Atividade 6: Resposta

ATIVIDADE 6

a) Hipóteses:

$H_0 : \mu \geq 85.0$ (Sem queda na precisão)

$H_a : \mu < 85.0$ (A precisão caiu)

b) Usamos o Teste Z porque o desvio padrão populacional é conhecido ($\sigma = 4.0$) **OU** o tamanho da amostra é adequadamente grande ($n = 36 \geq 30$) (bastaria um dos dois).

c) Calcular a Estatística de Teste (Z_{test}):

$$Z_{test} = \frac{\bar{x} - \mu_0}{\frac{\sigma}{\sqrt{n}}} = \frac{84.0 - 85.0}{\frac{4.0}{\sqrt{36}}} = \frac{-1.0}{\frac{4.0}{6}} = -1.50$$

d) Comparação e Decisão:

Usando a internet para um teste unilateral (cauda à esquerda) com $\alpha = 0.05$, encontramos:

RESPOSTA

$$Z_{crit} = -1.645$$

Nosso Z_{test} calculado (-1.50) **não** está mais a fundo na região crítica do que Z_{crit} (-1.645). Como $-1.50 > -1.645$, **Não Rejeitamos H_0** .

Nota Estatística Crucial:

Falhar em rejeitar H_0 NÃO significa que aceitamos H_0 . Isso significa simplesmente que não temos evidências suficientes para provar H_a .

Decisão de Negócios da IA:

A queda observada na precisão **não é estatisticamente significativa**. Nenhuma intervenção de emergência ou reversão é justificada no momento, mas a equipe deve continuar monitorando os dados da nova cidade.




3. Encerramento

3.1. Recomendações para casa

3.1. Recomendações para casa

- Faça os exercícios dos cards na Adalove.
 - Resolver os exercícios ajuda muito no aprendizado.
- Reveja o conteúdo. Se tiver alguma dúvida, pergunte ao professor ou ao monitor.



3.1. Recomendações para casa

- O próximo slide apresenta os **tópicos-chave** do **desafio** da próxima instrução, sobre esta semana.
 - **Todo o conteúdo de autoestudo** será avaliado no desafio (e não apenas o que foi discutido no encontro de instrução).



- **Estude para aprender**, não para fazer provas.
- O que você aprende nos módulos será útil ao longo do curso e, principalmente, na sua **vida profissional**.

3.1. Recomendações para casa

Para o **desafio** do próximo encontro, estude **todo o conteúdo** desta semana, com atenção especial aos seguintes **tópicos-chave**:

a) **Teorema do Limite Central:**

- Conceito e aplicabilidade
- Erro Padrão da Média
- Impacto do tamanho da amostra

b) **Intervalos de Confiança:**

- Estimativas pontuais vs. intervalares
- Margem de erro e confiança
- Cálculo do tamanho da amostra

c) **Fundamentos de Testes de Hipóteses:**

- Hipóteses Nula e Alternativa
- Erros do Tipo I e Tipo II
- Testes unilaterais vs. bilaterais

d) **Estatísticas de Teste (Z e T):**

- Distribuições Normal vs. T de Student
- Graus de liberdade
- Cálculo dos escores Z e T

3.2. Recomendações para casa

- Caso necessite de atendimento extraclasse, o professor disponibiliza os seguintes horários (mediante contato prévio no Slack):
 - Quartas-feiras: 16:00 – 17:00
 - Quintas-feiras: 12:00 – 13:00
- Acesse o link do Google Meet:


<https://meet.google.com/eqe-ydyv-fqq>

3.2. Feedback da Instrução



3.2. Feedback da Instrução

- Preencha o seu **feedback** sobre o encontro de instrução na Adalove.
- Comentários e sugestões são muito bem vindos e ajudarão a melhorar os próximos encontros.



Obrigado.
Bons estudos.

Prof. Geraldo Magela Severino Vasconcelos

geraldo.vasconcelos@prof.inteli.edu.br

Elaboração dos Slides: Prof. Henrique Paiva

Revisão técnica: Profs. Geraldo Magela e Leandro Mundim

Propósito: Material de uso compartilhado entre os docentes do primeiro ano, visando à padronização e ao alinhamento de conteúdo entre as turmas.

Declaração de uso de IA: Conteúdo de autoria humana, com uso pontual de ferramentas de IA (Gemini, ChatGPT e DeepSeek) para formulação de exemplos, geração de figuras, tradução de conteúdo e preparação de código em LaTeX e Python. Todo o conteúdo foi revisado, validado e aprovado por curadoria técnica humana.

