

Transformações lineares

Prof. Geraldo Magela Severino Vasconcelos

Set/2026



inteli

1. Planejamento e Rotinas Iniciais

1.1. Instruções do Módulo

1.2. Desafio (08:00-08:45)

1.3. Autoestudos no ateliê (08:45-10:00)

1.4. Daily Meeting (10:00-10:15)

2. Instrução de Hoje

2.1. Aplicação aos projetos (10:15-10:20)

2.2. Transformações Lineares e Prova de Linearidade (10:20-10:55)

2.3. Autovalores e Autovetores
(10:55-11:30)

2.4. Diagonalização de Matrizes
(11:30-12:00)

3. Encerramento

3.1. Atividades extras (Opcionais)

3.2. Recomendações para casa

3.3. Feedback da Instrução

Clique em um título acima para navegar e em  **Índice** para voltar.



1. Planejamento e Rotinas Iniciais



Índice



1.1. Instruções do Módulo

1.1. Instruções do Módulo

Planejamento:

- Semana 2: Distribuições de Probabilidade **FA**
- Semana 3: Estatística Indutiva - Estimação Intervalar e Teste de Hipóteses **FA**
- Semana 4: Definição de função de várias variáveis e representação gráfica **FT**
- Semana 5: Derivadas Parciais **FT**
- Semana 6: Integral Múltipla **FT**
- Semana 8: Transformações lineares **FA**



FT Frente transversal (semanas 4, 5 e 6): conecta todos os módulos do primeiro ano.

FA Frente aplicada (semanas 2, 3 e 8): aplicação mais imediata ao projeto.

1.1. Instruções do Módulo

Calendário 2026.2A:



Sem	Datas	Seg	Ter	Qua	Qui	Sex
1	Ago 03-07				ES11.T13: manhã	
2	Ago 10-14		IN03.T26: manhã IN03.T26: tarde	IN03.T29: manhã IN03.T29: tarde		
3	Ago 17-21		IN03.T29: manhã IN03.T29: tarde	ES11.T13: manhã	IN03.T26: manhã IN03.T26: tarde	
4	Ago 24-28		IN03.T29: manhã IN03.T29: tarde	IN03.T26: manhã		
5	Ago 31- Set 04		IN03.T29: manhã IN03.T29: tarde	IN03.T26: manhã	ES11.T13: manhã	
6	Set 07-11		IN03.T26: manhã IN03.T26: tarde	IN03.T29: manhã		
7	Set 14-18		ES11.T13: manhã			
8	Set 21-25		IN03.T29: manhã IN03.T29: tarde	IN03.T26: manhã		
9	Set 28- Out 02					
10	Out 05-09					



1.2. Desafio (08:00-08:45)

1.2. Desafio de Matemática (08:00-08:45)

Desafio de Matemática e Física

- Sobre a mesa: apenas **caneta**, **lapiseira**, **borracha** e o **desafio**.
- **Individual** e **sem consulta**.
- Valor: **dois pontos** na Adalove.
- Duração: **45 minutos**.
- No papel; use **caneta** (lápiz só no rascunho).
- Após terminar, mova seu card para **feito** na **Adalove**.



Bom trabalho!



1.3. Autoestudos no ateliê (08:45-10:00)

1.3. Autoestudos: Informações (1)

1. A pedido dos alunos, para cada tema de Matemática e Física, pelo menos três cards estão disponíveis na Adalove:

a) Card de capítulo do livro;



b) Card de videoaula;

- preferencialmente da UNIVESP, uma faculdade pública de alta qualidade, voltada ao ensino remoto;
- **alternativa opcional** ao capítulo do livro (não é preciso estudar ambos).

c) Card de exercícios resolvidos:

- **altamente recomendados** - ajudam muito na aprendizagem;
- tente resolvê-los sozinho antes de conferir as respostas.

$$\begin{aligned} 1. f(x) &= x^3 + x - \sqrt{x+1} \\ 2. f(x) &= x^{1/3} + \frac{1}{\sqrt{x^2+8}} \\ 3. f(x) &= (x^{100}-1)\left(x^{7/2}-\sqrt{4x^3-1}+\frac{1}{x^5}\right) \\ 4. f(x) &= \frac{x^{13}+(50x^2-x^{36}-0.002)^2}{x^{80}+x^7-1000} \\ 5. f(x) &= \sin\left(\frac{x}{\sqrt{x^2+8}}\right) - \cos^4(\sqrt{x^2+8}) \end{aligned}$$

1.3. Autoestudos: Informações (2)

2. Cada encontro de instrução pode incluir breves revisões do conteúdo de autoestudo.
- a) Esta revisão é excepcional e complementar e **não substitui** o autoestudo;
 - b) No nosso modelo de sala invertida, é **essencial** que todos os alunos **concluam o autoestudo antes** do encontro de instrução.



3. Devido a limitações de tempo, nem todos os tópicos do autoestudo serão abordados durante o encontro.
- a) Todos os tópicos podem ser cobrados em avaliações.
 - b) **Dúvidas** sobre qualquer parte do autoestudo podem ser esclarecidas com o professor.

1.3. Autoestudos: Cards desta semana

- **Desafio de Matemática 5**

- Transformações lineares - Videoaula
- Autovalores e autovetores - Videoaula
- Diagonalização - Videoaula

- **Opcional:** Transformação linear, autovalor, autovetor e diagonalização - Livro

- **Opcional:** Exercícios - transformação linear, autovalor, autovetor e diagonalização

- **Optional (English):** Linear transformations - Book chapter
- **Optional (English):** Eigenvalues and eigenvectors - Book chapter
- **Optional (English):** Diagonalization - Book chapter





1.4. Daily Meeting (10:00-10:15)

1.4. Daily Meeting

Daily Meeting – 10:00-10:15

- O que fiz de ontem para hoje?
- O que aprendi de ontem para hoje?
- O que planejei fazer de hoje para amanhã?
- Tenho algum impedimento?




The image shows a modern, open-plan interior space, likely a museum or community center. The ceiling is a prominent feature, with green-painted metal trusses and exposed wooden beams. Long, horizontal light fixtures are suspended from the ceiling. Large, multi-paned windows in the background offer a view of the outdoors. In the foreground, there is a long wooden table with several black metal stools. To the right, a tall, dark digital display stands, showing the Intel logo and the text "BEM-VINDOS AO INTELI". Further right, there is a blue modular sofa and a small, square wooden table. A yellow metal railing with a mesh screen runs across the middle of the room.

2. Instrução de Hoje

Referências Principais


- Margalit, D.; Rabinoff, J. **Interactive Linear Algebra**.
[3.3. Linear Transformations](#) and [2.1. Eigenvalues and Eigenvectors](#)



2. Instrução de Hoje


Referências Principais

- Strang, G. S. **Introduction to Linear Algebra**, 6th Edition.
Wellesley-Cambridge Press, 2023. ISBN-13: 978-1733146678.



Referências Principais

- Kuttler, A. [A First Course in Linear Algebra](#) , 10th Anniversary Edition. Lyryx, 2023.




Referências Principais

- Doerr, A.; Levasseur, K. **Applied Discrete Structures**. [12.4.2. Diagonalization](#)



Referências Principais

- Poole, D. [Álgebra linear: uma introdução moderna](#), 2. ed. São Paulo: Cengage Learning, 2016. ISBN 9788522124015. Sections 4.1, 4.4, and 6.4.



2. Instrução de Hoje

Conteúdo em Inglês

- Inglês é o **idioma padrão** da Tecnologia.
- Entendê-lo é essencial para a sua **vida profissional**.



- Parte do nosso material será em inglês, como parte da preparação profissional de todos.
- A principal preocupação é a formação e a empregabilidade de quem ainda está aprendendo.
- O Inteli oferece **curso gratuito de inglês**. Aproveite esse recurso.

Aprender faz parte do processo. Em caso de dúvidas, pergunte sempre.

2. Instrução de Hoje

Aprendizado Ativo

- Esta apresentação contém slides teóricos, com um breve resumo.
 - Referência rápida para esclarecer dúvidas durante o encontro e ajudar nos autoestudos.
 - Estes slides **não serão seguidos** durante o encontro de instrução.
 - No encontro, os alunos serão convidados a explicar alguns conceitos, e em seguida passaremos às atividades.
- Lembre-se, você é responsável pelo **seu próprio aprendizado**.





2.1. Aplicação aos projetos (10:15-10:20)

2.1. Aplicação aos projetos

Turma 24: Saúde Suplementar

- Modelo preditivo para estimar demanda de pacientes por serviços especializados, cruzando dados históricos e demográficos.



- Projeção de dados: Mapear dados demográficos em novos espaços matemáticos para otimizar o aprendizado da IA.
- Engenharia de atributos: Reduzir a dimensionalidade do histórico médico para acelerar o treinamento do modelo.
- Padrões de sintomas: Identificar combinações clínicas principais que mais explicam a variação nas internações.
- Isolamento de risco: Desacoplar variáveis altamente correlacionadas para isolar fatores primários de saúde.

2.1. Aplicação aos projetos

Turma 25: Proteína Animal

- Modelos preditivos que conectam a produção mensal de proteína animal à demanda por ração e macroingredientes.
-
- a) Mapeamento de clima: Projetar variáveis genéticas e climáticas em um espaço latente focado em produtividade.
 - b) Normalização de safra: Aplicar matrizes de transformação nos dados agrícolas brutos antes da rede neural.
 - c) Fatores de consumo: Encontrar as direções principais de dados que mais afetam as flutuações no uso de ração.
 - d) Simplificação de dados: Reduzir a complexidade da matriz de macroingredientes para garantir previsões rápidas.



2.1. Aplicação aos projetos

Turma 26: Vendas de Veículos

- Ferramenta de predição mensal das vendas de veículos por segmento e motorização, cruzando indicadores macroeconômicos.



- Vetorização econômica:** Projetar indicadores econômicos em matrizes numéricas de propensão de compra.
- Alinhamento de mercado:** Rotacionar os dados de vendas no espaço vetorial para evidenciar comportamentos ocultos.
- Fatores latentes:** Extrair os indicadores econômicos estruturais que determinam a alta ou queda do ticket médio.
- Eliminação de ruído:** Excluir a redundância analítica entre variáveis com correlação forte, como juros e inflação.

2.1. Aplicação aos projetos

Turma 27: Óleo Diesel Agrícola


- Inteligência artificial para prever o consumo futuro e o momento ideal de compra de óleo diesel por produtores rurais.
-
- a) Tratamento de features: Converter dados brutos de clima e relevo em características numéricas otimizadas para a IA.
 - b) Redução espacial: Projetar coordenadas das fazendas em dimensões menores para cálculo logístico rápido.
 - c) Variação de consumo: Descobrir quais combinações exatas de solo e clima maximizam a flutuação de combustível.
 - d) Fatoração de histórico: Decompor a matriz de histórico de vendas para isolar eventos que antecipam compras.



2.1. Aplicação aos projetos

Turma 28: Detratores de NPS

- Modelo de classificação para antecipar a probabilidade de passageiros avaliarem negativamente a experiência da viagem.



- a) **Classificação de risco:** Projetar variáveis de jornada do passageiro em um plano hiperdimensional preditivo.
- b) **Pesos operacionais:** Aplicar transformações matriciais para priorizar falhas graves durante o cálculo da IA.
- c) **Componentes principais:** Isolar os fatores estruturais que melhor separam clientes promotores de detratores.
- d) **Causa raiz preditiva:** Descorrelacionar variáveis da viagem para determinar o problema que derruba a nota.

2.1. Aplicação aos projetos

Turma 29: Previsão Térmica

- Modelo preditivo para estimar a temperatura de fogões com alta precisão utilizando históricos de simulação numérica.
-
- a) Compressão geométrica: Mapear a malha complexa do fogão em tensores menores para alimentar a rede neural.
 - b) Alinhamento térmico: Rotacionar as matrizes para alinhar o modelo preditivo ao fluxo de calor.
 - c) Modos de propagação: Isolar as vias térmicas primárias que dominam o aquecimento acelerado das portas.
 - d) Aceleração computacional: Decompor a matriz de simulação original para reduzir o tempo de predição.



The background image shows a modern lecture hall or study area. The ceiling is made of green corrugated metal with exposed structural beams and several small, white, cylindrical pendant lights. The room is furnished with long, light-colored wooden tables and grey ergonomic office chairs. Large windows in the background offer a view of green trees outside. The overall atmosphere is bright and contemporary.

2.2. Transformações Lineares e Prova de Linearidade (10:20-10:55)



2.2.1. Teoria e Contexto do Projeto



Índice

2.2.1. Transformações como Funções Vetoriais

PARA AUTOESTUDO

Uma **Transformação** T é essencialmente uma função, mas em vez de mapear números únicos (escalares), ela mapeia **vetores** de um espaço para outro.

- **A Analogia Escalar:** Uma função recebe uma entrada x , aplica uma regra f e produz uma saída $f(x)$.
- **A Realidade Vetorial:** Uma transformação recebe um vetor de entrada u , aplica uma regra de mapeamento T e produz um novo vetor $T(u)$.



2.2.1. Provando a Linearidade

MEMORIZE

- Uma transformação é **linear** se preservar a **adição de vetores** e a **multiplicação por escalar**

$$T(u + v) = T(u) + T(v)$$

$$T(\alpha u) = \alpha T(u)$$

- Podemos provar ambas com:

$$T(\alpha u + \beta v) = \alpha T(u) + \beta T(v)$$

para quaisquer vetores u, v e escalares α, β

PARA AUTOESTUDO

CUIDADO – Metodologia de Prova

- ✗ **Nunca** assuma que a igualdade é verdadeira (ex., escrever a equação completa e simplificar para $0 = 0$).
- ✗ Esta **não** é uma prova válida.

Abordagem correta

- Comece apenas com o **lado esquerdo**.
- Aplique a definição de T .
- Simplifique a expressão.
- Verifique se ele é igual ao **lado direito**.

2.2.1. A Matriz de Transformação Padrão

PARA AUTOESTUDO

Toda transformação **linear** T mapeando $\mathbb{R}^n$ para $\mathbb{R}^m$ pode ser representada por uma matriz A , de forma que $T(u) = Au$.

- **Encontrando a Matriz A :** Para construir essa matriz, simplesmente aplicamos a transformação T aos **vetores da base padrão** do nosso espaço (ex., $e_1 = (1, 0)$ e $e_2 = (0, 1)$).
- **Construindo as Colunas:** Os vetores de saída $T(e_1)$ e $T(e_2)$ se tornam as colunas da nossa matriz padrão A :


$$A = [T(e_1) \quad T(e_2) \quad \dots]$$

2.2.1. Contexto do Projeto: Engenharia de Atributos

Principais Conclusões: Em modelos preditivos de IA, **transformações lineares** são usadas para projetar atributos brutos em novos espaços matemáticos, ajudando as redes neurais a separar padrões com mais facilidade.

Em nosso Modelo Preditivo de IA:

- No aprendizado profundo, cada camada densa executa a operação $y = Wx + b$, onde Wx é uma **transformação linear** e o termo $+b$ desloca o espaço.
- A **Não-linearidade** é introduzida posteriormente por meio de funções de ativação (como ReLU).
- **A Matriz é o Conhecimento:** Quando uma IA aprende durante o treinamento, ela ajusta matematicamente os valores de suas matrizes W para encontrar as transformações ideais para os dados.



2.2.2. Atividades



Índice

2.2.2. Provando a Linearidade

ATIVIDADE 1

Cenário:

Você está projetando duas funções de pré-processamento de dados para um pipeline de IA. Elas mapeiam vetores de entrada em novas representações. As regras de transformação são:

- a) $T_1 : \mathbb{R}^3 \rightarrow \mathbb{R}^2, \quad T_1((x, y, z)) = (2x + y + z, x - 3y)$
- b) $T_2 : \mathbb{R}^2 \rightarrow \mathbb{R}^2, \quad T_2((x, y)) = (x + 1, xy)$

Tarefa: Use a equação mestre $T(\alpha u + \beta v) = \alpha T(u) + \beta T(v)$ para provar se cada transformação é linear ou não-linear.

Nota: Em $T((x, y))$, os parênteses internos indicam as coordenadas do vetor e os parênteses externos indicam a transformação. A notação pode ser simplificada para $T(x, y)$.

2.2.2. Matriz Padrão de Transformação

ATIVIDADE 2

Cenário:

Em um pipeline de IA, as transformações são aplicadas a milhões de vetores de dados. Para tornar esse processo computacionalmente eficiente, as transformações lineares são implementadas como multiplicações de matrizes, pois o hardware moderno é altamente otimizado para essa operação.

Na atividade anterior, você determinou qual transformação é linear. Apenas essa transformação pode ser representada por uma matriz padrão A , de forma que $T(v) = Av$.

Tarefa:

Usando a transformação que você provou ser linear, encontre sua matriz padrão.

2.2.3. Respostas



Índice

2.2.3. Atividade 1a: Resposta

ATIVIDADE 1a

RESPOSTA

$$\text{a) } T_1 : \mathbb{R}^3 \rightarrow \mathbb{R}^2, \quad T_1((x, y, z)) = (2x + y + z, x - 3y)$$

Seja $u = (u_x, u_y, u_z)$ e $v = (v_x, v_y, v_z)$.

$$\begin{aligned} T_1(\alpha u + \beta v) &= T_1((\alpha u_x + \beta v_x, \alpha u_y + \beta v_y, \alpha u_z + \beta v_z)) = \\ &= \left(2(\alpha u_x + \beta v_x) + (\alpha u_y + \beta v_y) + (\alpha u_z + \beta v_z), (\alpha u_x + \beta v_x) - 3(\alpha u_y + \beta v_y) \right) = \\ &= \alpha(2u_x + u_y + u_z, u_x - 3u_y) + \beta(2v_x + v_y + v_z, v_x - 3v_y) \\ &= \alpha T_1(u) + \beta T_1(v) \end{aligned}$$

$$T_1(\alpha u + \beta v) = \alpha T_1(u) + \beta T_1(v) \Leftrightarrow T_1 \text{ é linear.}$$

2.2.3. Atividade 1b: Resposta

ATIVIDADE 1b

RESPOSTA

$$\text{b) } T_2 : \mathbb{R}^2 \rightarrow \mathbb{R}^2, \quad T_2((x, y)) = (x + 1, xy)$$

Seja $u = (u_x, u_y)$ e $v = (v_x, v_y)$.

$$\begin{aligned} \bullet T_2(\alpha u + \beta v) &= T_2((\alpha u_x + \beta v_x, \alpha u_y + \beta v_y)) = \\ &= (\alpha u_x + \beta v_x + 1, (\alpha u_x + \beta v_x)(\alpha u_y + \beta v_y)) \end{aligned}$$

enquanto

$$\bullet \alpha T_2(u) + \beta T_2(v) = (\alpha(u_x + 1) + \beta(v_x + 1), \alpha u_x u_y + \beta v_x v_y)$$

As expressões são diferentes (termo constante e produtos cruzados).

$$T_2(\alpha u + \beta v) \neq \alpha T_2(u) + \beta T_2(v) \Leftrightarrow T_2 \text{ não é linear.}$$

2.2.3. Atividade 2: Resposta

ATIVIDADE 2, PARTE 1

RESPOSTA

Usamos a transformação linear encontrada na Atividade 1:

$$T_1 : \mathbb{R}^3 \rightarrow \mathbb{R}^2, \quad T_1((x, y, z)) = (2x + y + z, x - 3y)$$

A base padrão do $\mathbb{R}^3$ é: $e_1 = (1, 0, 0)$, $e_2 = (0, 1, 0)$, $e_3 = (0, 0, 1)$.

Aplicando a transformação a cada vetor da base:

$$T_1((1, 0, 0)) = (2 \cdot 1 + 0 + 0, 1 - 3 \cdot 0) = (2, 1),$$

$$T_1((0, 1, 0)) = (2 \cdot 0 + 1 + 0, 0 - 3 \cdot 1) = (1, -3),$$

$$T_1((0, 0, 1)) = (2 \cdot 0 + 0 + 1, 0 - 3 \cdot 0) = (1, 0).$$

Portanto, a matriz de transformação padrão é

$$A = \begin{bmatrix} 2 & 1 & 1 \\ 1 & -3 & 0 \end{bmatrix}.$$

2.2.3. Atividade 2: Resposta

ATIVIDADE 2, PARTE 2

RESPOSTA

Vamos verificar se a matriz executa a mesma transformação:

$$A \cdot \begin{bmatrix} x \\ y \\ z \end{bmatrix} = \begin{bmatrix} 2 & 1 & 1 \\ 1 & -3 & 0 \end{bmatrix} \cdot \begin{bmatrix} x \\ y \\ z \end{bmatrix} = \begin{bmatrix} 2x + y + z \\ x - 3y \end{bmatrix} = T_1((x, y, z)).$$

Conclusão da IA:

Em vez de avaliar funções manualmente linha por linha, o pipeline de IA agora pode projetar milhões de pontos de dados simultaneamente por meio da multiplicação de matrizes ($A \cdot X$). É assim que as GPUs aceleram matematicamente a engenharia de atributos.



2.3. Autovalores e Autovetores (10:55-11:30)

2.3.1. Teoria e Contexto do Projeto



Índice

2.3.1. Definição de Autovetores e Autovalores

PARA AUTOESTUDO


Quando uma matriz transforma um espaço, a maioria dos vetores muda de direção.

Autovetores são os vetores não-nulos especiais cuja direção permanece inalterada.

- **Equação de Autovalor:** Para um autovetor v , aplicar a matriz de transformação A é equivalente a simplesmente escalar o vetor por um número escalar λ , chamado de **autovalor**.

$$Av = \lambda v$$

- **Interpretação:** A matriz A apenas estica, encolhe ou inverte o autovetor v , mas nunca o rotaciona.



2.3.1. A Equação Característica

MEMORIZE

PARA AUTOESTUDO

Para encontrar os autovalores de uma matriz A , manipulamos a equação de definição.

$$Av = \lambda v \Rightarrow Av - \lambda v = 0 \Rightarrow (A - \lambda I)v = 0$$

Para que exista um autovetor não-nulo v , a matriz $(A - \lambda I)$ não deve ser inversível (ou a única solução seria $v = 0$). Portanto, seu determinante deve ser zero.

Equação Característica:

$$\det(A - \lambda I) = 0$$

Resolver esta equação fornece os autovalores $(\lambda_1, \lambda_2, \dots)$.

2.3.1. Encontrando Autovetores

PARA AUTOESTUDO

Resolvida a equação característica e encontrados os autovalores $(\lambda_1, \lambda_2, \dots)$, podemos encontrar seus respectivos **autovetores**.

1. **Substituir:** Avalie um autovalor por vez (ex., λ_1) e substitua-o de volta no sistema modificado: $(A - \lambda_1 I)v = 0$
2. **Resolver o Sistema Homogêneo:** Sempre resultará em um sistema de equações indefinido (com infinitas soluções). Nós o resolvemos para encontrar a relação base entre as variáveis (ex., $x = y$).
3. **Escolher um vetor representativo:** Escolha um valor simples e não-nulo para uma variável para construir o autovetor final.
ex., se $x = y$, escolha $x = 1 \Rightarrow v = [1, 1]^T$

2.3.1. No Projeto: Isolando Fatores Preditivos

Principais Conclusões: Na IA, uma matriz de covariância representa como diferentes atributos variam juntos. Seus **autovetores** informam as direções independentes dos dados, enquanto os **autovalores** medem a importância da variância nessas direções.

Em nosso Modelo Preditivo de IA:

- **Componentes Independentes:** Dados complexos, como vendas de veículos ou sensores térmicos, possuem variáveis altamente correlacionadas. Os autovetores desacoplam essas variáveis, criando fatores preditivos independentes.
- **Importância dos Atributos:** Um autovalor de $\lambda = 50$ significa que aquele autovetor específico (direção) contém muito mais informações estruturais sobre o problema do que um autovalor de $\lambda = 2$.



2.3.2. Atividades



Índice

2.3.2. Encontrando Autovalores

ATIVIDADE 3

Cenário:

Durante a fase de pré-processamento de dados do seu modelo preditivo, a IA calcula a matriz de covariância de dois atributos altamente correlacionados (ex., custo e receita).

A matriz é dada por:

$$A = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}$$

Tarefa:

Escreva a equação característica para esta matriz específica e resolva-a algebricamente para encontrar seus dois autovalores λ_1 e λ_2 .

2.3.2. Calculando Autovetores

ATIVIDADE 4

Cenário:

Você encontrou com sucesso os autovalores para a matriz de covariância dos atributos da IA. Para finalizar a extração dos componentes independentes, você precisa dos vetores propriamente ditos.

Matriz:

$$A = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}$$

Tarefa:

Usando os dois autovalores que você encontrou na Atividade 3, calcule os dois autovetores associados (v_1 e v_2).

2.3.3. Respostas



Índice

2.3.3. Atividade 3: Resposta

ATIVIDADE 3

Passo 1: Monte a matriz $(A - \lambda I)$

$$A - \lambda I = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix} - \begin{bmatrix} \lambda & 0 \\ 0 & \lambda \end{bmatrix} = \begin{bmatrix} 3 - \lambda & 1 \\ 1 & 3 - \lambda \end{bmatrix}$$

Passo 2: Escreva a equação característica

O determinante deve ser zero:

$$\det(A - \lambda I) = 0$$

$$(3 - \lambda)(3 - \lambda) - (1)(1) = 0$$

$$(9 - 3\lambda - 3\lambda + \lambda^2) - 1 = 0$$

$$\lambda^2 - 6\lambda + 8 = 0$$

Passo 3: Resolva a equação quadrática

Precisamos de dois números cuja soma seja 6 e o produto seja 8. Esses números são 4 e 2.

$$(\lambda - 4)(\lambda - 2) = 0$$

$$\lambda_1 = 4, \quad \lambda_2 = 2$$

Conclusão Estatística:

No contexto da IA, o componente principal associado a $\lambda = 4$ carrega o dobro da variância (informação estrutural) em relação ao componente associado a $\lambda = 2$.

2.3.3. Atividade 4: Resposta

ATIVIDADE 4

a) Autovetor para $\lambda_1 = 4$

Substitua $\lambda = 4$ em $(A - \lambda I)v = 0$:

$$\begin{bmatrix} 3-4 & 1 \\ 1 & 3-4 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$
$$\begin{bmatrix} -1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

Ambas as linhas resultam na mesma equação:

$$-x + y = 0 \Rightarrow x = y$$

Seja $y = 1$, então $x = 1$:

$$v_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

Conclusão da IA: Os dois atributos originais correlacionados são agora mapeados para dois novos vetores independentes (v_1 e v_2). A IA agora pode aprender a partir dessas direções separadas.

RESPOSTA

b) Autovetor para $\lambda_2 = 2$

Substitua $\lambda = 2$ em $(A - \lambda I)v = 0$:

$$\begin{bmatrix} 3-2 & 1 \\ 1 & 3-2 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$
$$\begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

Ambas as linhas resultam na mesma equação:

$$x + y = 0 \Rightarrow x = -y$$

Seja $y = 1$, então $x = -1$:

$$v_2 = \begin{bmatrix} -1 \\ 1 \end{bmatrix}$$



2.4. Diagonalização de Matrizes (11:30-12:00)

2.4.1. Teoria e Contexto do Projeto



Índice

2.4.1. O Conceito de Diagonalização

PARA AUTOESTUDO

A diagonalização é a decomposição no produto de três matrizes específicas.

- Equação de Diagonalização:

$$A = PDP^{-1}$$

- Construindo P e D :

- Encontre os autovalores e autovetores de A .
- P : Matriz com os **autovetores de A** em suas colunas.
- D : Matriz diagonal com os **autovalores de A** em sua diagonal principal (e zeros em todos os outros lugares).

2.4.1. Condição para Diagonalização

PARA AUTOESTUDO

Nem todas as matrizes podem ser diagonalizadas. Precisamos de direções independentes suficientes para formar um sistema de coordenadas completo e inversível.

- **Condição Central:**

Uma matriz A de $n \times n$ é diagonalizável se e somente se tiver **n autovetores linearmente independentes**.

- **Por que isso é necessário?**

Se P não tiver n colunas linearmente independentes, seu determinante será zero. Se $\det(P) = 0$, a matriz inversa P^{-1} **não existe**, e a equação $A = PDP^{-1}$ falha.

2.4.1. Calculando Potências de Matrizes

PARA AUTOESTUDO

- A diagonalização $A = PDP^{-1}$ simplifica drasticamente calcular **potências de matrizes**.
- Observe o padrão com A^3 :

$$\begin{aligned} A^3 &= AAA = (PDP^{-1})(PDP^{-1})(PDP^{-1}) = (PD \color{blue}{P^{-1}} \color{blue}{P} D \color{blue}{P^{-1}} \color{blue}{P} D P^{-1}) = \\ &= (PD \color{blue}{I} \color{blue}{I} D P^{-1}) = (PD \color{blue}{D} \color{blue}{D} \color{blue}{D} P^{-1}) \Rightarrow A^3 = PD^3 P^{-1} \end{aligned}$$

- O mesmo padrão ocorre para qualquer inteiro positivo k : $A^k = PD^k P^{-1}$
- Calcular D^k requer apenas elevar as **entradas da diagonal** à potência de k .

$$D = \begin{bmatrix} \lambda_1 & 0 & 0 \\ 0 & \lambda_2 & 0 \\ 0 & 0 & \lambda_3 \end{bmatrix} \Rightarrow D^k = \begin{bmatrix} \lambda_1^k & 0 & 0 \\ 0 & \lambda_2^k & 0 \\ 0 & 0 & \lambda_3^k \end{bmatrix}$$

2.4.1. No Projeto: Aceleração Computacional

Principal Conclusão: No treinamento de IA, as matrizes costumam ser multiplicadas por si mesmas milhares de vezes (A^k). A multiplicação normal é muito lenta. A **Diagonalização** simplifica muito esse cálculo, além de **desacoplar** matematicamente as variáveis.

Em nosso Modelo Preditivo de IA:

- **Potências de matrizes rápidas:** Muitos modelos iterativos exigem transformações repetidas de matrizes, onde A^k aparece naturalmente.
- **Dinâmicas desacopladas:** Na base diagonal, cada autovalor evolui independentemente, simplificando muito a computação.
- **Interpretação do modelo:** A representação diagonal separa o sistema em modos independentes, ajudando-nos a entender o crescimento, o decaimento e o comportamento de longo prazo.



2.4.2. Atividades



Índice

2.4.2. Diagonalização e Aceleração

ATIVIDADE 5

Cenário:

Nas Atividades 3 e 4, você analisou a matriz de covariância dos atributos da IA:

$$A = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}$$

O modelo de IA precisa propagar esses dados por 4 etapas de tempo, o que requer o cálculo de A^4 . Multiplicar A por si mesma várias vezes não é eficiente.

Tarefa:

- Diagonalize A : primeiro, construa as matrizes P e D usando os autovalores e autovetores que você já obteve; em seguida, calcule P^{-1} .
- Calcule A^4 eficientemente usando a propriedade $A^4 = PD^4P^{-1}$.

2.4.2. Polinômio Característico para Matriz 3x3

ATIVIDADE 6 (OPCIONAL, PARA CASA)

Cenário:

Um novo subsistema de IA rastreia três variáveis. A matriz de covariância B para este subsistema é 3×3 , definida como:

$$B = \begin{bmatrix} 2 & 0 & 0 \\ 0 & 3 & 1 \\ 0 & 1 & 3 \end{bmatrix}$$

Tarefas:

- Escreva a equação característica $\det(B - \lambda I) = 0$.
- Resolva o polinômio para encontrar todos os três autovalores.
- Encontre o autovetor associado ao maior autovalor.

2.4.3. Respostas



Índice

2.4.3. Atividade 5: Resposta

ATIVIDADE 5

Passo 1: Construir P e D

Coloque os autovetores nas colunas e os autovalores na diagonal:

$$P = \begin{bmatrix} 1 & -1 \\ 1 & 1 \end{bmatrix}, \quad D = \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix}$$

Passo 2: Encontrar P^{-1}

$$\det(P) = (1)(1) - (-1)(1) = 2$$

$$P^{-1} = \frac{1}{2} \begin{bmatrix} 1 & 1 \\ -1 & 1 \end{bmatrix} = \begin{bmatrix} 0.5 & 0.5 \\ -0.5 & 0.5 \end{bmatrix}$$

Passo 3: Calcular D^4

Basta elevar os elementos da diagonal à 4ª potência:

$$D^4 = \begin{bmatrix} 4^4 & 0 \\ 0 & 2^4 \end{bmatrix} = \begin{bmatrix} 256 & 0 \\ 0 & 16 \end{bmatrix}$$

RESPOSTA

Passo 4: Calcular PD^4P^{-1}

Primeiro, multiplique PD^4 :

$$PD^4 = \begin{bmatrix} 1 & -1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 256 & 0 \\ 0 & 16 \end{bmatrix} = \begin{bmatrix} 256 & -16 \\ 256 & 16 \end{bmatrix}$$

Em seguida, multiplique (PD^4) por P^{-1} :

$$\begin{bmatrix} 256 & -16 \\ 256 & 16 \end{bmatrix} \begin{bmatrix} 0.5 & 0.5 \\ -0.5 & 0.5 \end{bmatrix} = \begin{bmatrix} 128 + 8 & 128 - 8 \\ 128 - 8 & 128 + 8 \end{bmatrix}$$

$$A^4 = \begin{bmatrix} 136 & 120 \\ 120 & 136 \end{bmatrix}$$

Conclusão da IA:

Evitando a multiplicação de matrizes densas e contando com a diagonal D^k , o algoritmo atinge alta **eficiência computacional**.

2.4.3. Atividade 6: Resposta

ATIVIDADE 6

RESPOSTA

a) Equação Característica:

$$\det \begin{bmatrix} 2 - \lambda & 0 & 0 \\ 0 & 3 - \lambda & 1 \\ 0 & 1 & 3 - \lambda \end{bmatrix} = 0$$

b) Resolvendo o Polinômio:

Expanda ao longo da primeira coluna (graças aos zeros):

$$\begin{aligned} (2 - \lambda) \cdot [(3 - \lambda)^2 - 1] &= 0 \\ (2 - \lambda) \cdot (\lambda^2 - 6\lambda + 8) &= 0 \\ (2 - \lambda) \cdot (\lambda - 2) \cdot (\lambda - 4) &= 0 \end{aligned}$$

Os autovalores são: $\lambda_1 = 4$, $\lambda_2 = 2$
(multiplicidade 2).

c) Autovetor para $\lambda_1 = 4$:

Substitua $\lambda = 4$ em $(B - \lambda I)v = 0$:

$$\begin{bmatrix} -2 & 0 & 0 \\ 0 & -1 & 1 \\ 0 & 1 & -1 \end{bmatrix} \begin{bmatrix} x \\ y \\ z \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

A linha 1 resulta em: $-2x = 0 \Rightarrow x = 0$.

A linha 2 resulta em: $-y + z = 0 \Rightarrow y = z$.

Seja $z = 1 \Rightarrow y = 1$.

$$v_{\lambda=4} = \begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix}$$



3. Encerramento



3.1. Atividades extras (Opcionais)

3.1.1. Transformações Lineares

ATIVIDADE 7 (OPCIONAL, PARA CASA)



- **Teoria** (para referência):

[Transformações de Matrizes \(Transformações Lineares\)](#)

- **Atividades Selecionadas:**

[Questions: 9289, 9290, 9296, 9297, 17800, 17802](#)



3.1.2. Autovalores e Autovetores

ATIVIDADE 8 (OPCIONAL, PARA CASA)

- **Teoria** (para referência):

[Autovalores e Autovetores](#)

- **Atividades Selecionadas:**

[Questions: 17804, 17805, 17808, 17809, 17810, 17811](#)






3.2. Recomendações para casa

3.2. Recomendações para casa

- Faça os exercícios dos cards na Adalove.
 - Resolver os exercícios ajuda muito no aprendizado.
- Reveja o conteúdo. Se tiver alguma dúvida, pergunte ao professor ou ao monitor.



3.2. Recomendações para casa

- Caso necessite de atendimento extraclasse, o professor disponibiliza os seguintes horários (mediante contato prévio no Slack):
 - Quartas-feiras: 16:00 – 17:00
 - Quintas-feiras: 12:00 – 13:00
- Acesse o link do Google Meet:


<https://meet.google.com/eqe-ydyv-fqq>

The image shows a bright, modern classroom or lecture hall. The ceiling is made of green corrugated metal with exposed wooden beams and modern lighting fixtures. The room is filled with long wooden tables and grey ergonomic chairs. Large windows in the background offer a view of green trees. The overall atmosphere is clean and contemporary.

3.3. Feedback da Instrução

3.3. Feedback da Instrução

- Preencha o seu **feedback** sobre o encontro de instrução na Adalove.
- Comentários e sugestões são muito bem-vindos e ajudarão a melhorar os próximos encontros.



Obrigado.
Bons estudos.

Prof. Geraldo Magela Severino Vasconcelos

geraldo.vasconcelos@prof.inteli.edu.br

Elaboração dos Slides: Prof. Henrique Paiva

Revisão técnica: Profs. Geraldo Magela e Leandro Mundim

Propósito: Material de uso compartilhado entre os docentes do primeiro ano, visando à padronização e ao alinhamento de conteúdo entre as turmas.

Declaração de uso de IA: Conteúdo de autoria humana, com uso pontual de ferramentas de IA (Gemini, ChatGPT e DeepSeek) para formulação de exemplos, geração de figuras, tradução de conteúdo e preparação de código em LaTeX e Python. Todo o conteúdo foi revisado, validado e aprovado por curadoria técnica humana.

